

Nama: Tegar Scaesario

NIM: A11.2024.15547

Matkul: Pembelajaran Mesin – A11.4410

1. SOAL ANALISIS

1) Jelaskan masalah yang ingin diselesaikan

Jawab:

Obesitas merupakan masalah kesehatan global yang terus meningkat setiap tahun dan meningkatkan risiko penyakit kronis seperti diabetes melitus, hipertensi, penyakit jantung, dan stroke. Tingkat obesitas dipengaruhi oleh karakteristik fisik (usia, jenis kelamin, tinggi, berat badan) dan gaya hidup (pola makan, konsumsi makanan tinggi kalori, aktivitas fisik, konsumsi air, kebiasaan merokok/alkohol, riwayat keluarga, serta moda transportasi).

Penelitian ini bertujuan memprediksi tingkat obesitas seseorang berdasarkan karakteristik fisik dan gaya hidup menggunakan algoritma *Machine Learning*, memanfaatkan **Obesity Levels Dataset** dari UCI Machine Learning Repository. Model ini diharapkan membantu masyarakat maupun tenaga kesehatan melakukan deteksi dini risiko obesitas, sehingga intervensi pola hidup sehat dapat dilakukan sebelum kondisi berkembang lebih serius — analog dengan tujuan sistem deteksi dini risiko akademik (mis. dropout), yaitu intervensi sebelum masalah menjadi kronis.

2) Tentukan target klasifikasi dan jelaskan mengapa termasuk supervised classification

Jawab:

Target klasifikasi adalah atribut **NObesidad**, berisi 7 kategori tingkat obesitas: *Insufficient Weight*, *Normal Weight*, *Overweight Level I*, *Overweight Level II*, *Obesity Type I*, *Obesity Type II*, *Obesity Type III*.

Kasus ini termasuk **supervised classification** karena dataset sudah memiliki label kelas yang diketahui — model belajar pola hubungan fitur-label lalu memprediksi kelas pada data baru. Ini bukan **regresi**, karena target berupa kategori diskrit, bukan nilai numerik kontinu. Ini juga bukan **clustering**, karena clustering bersifat unsupervised (tanpa label), sedangkan data di sini sudah berlabel. Supervised classification adalah pendekatan paling tepat secara ilmiah untuk masalah ini.

3) Mini Review Paper (2026)

Jawab:

Komponen	Uraian
Penulis	Salliah Shafi, Gufran Ahmad Ansari, Lamees Alhazaa
Tahun	2026
Jurnal	<i>Systems and Soft Computing</i>
DOI	https://doi.org/10.1016/j.sasc.2026.200472
Judul	<i>Optimizing Machine Learning Models for Obesity Risk Prediction through Hyperparameter Tuning</i>
Metode	Decision Tree, SVM, KNN, dan Logistic Regression; feature engineering dengan Cuckoo Search; hyperparameter tuning via Grid Search/Random Search; explainability dengan SHAP
Dataset	UCI Obesity Dataset
Metrik Evaluasi	Accuracy, Precision, Recall, F1-Score
Hasil Utama	Logistic Regression meraih akurasi tertinggi (99,63%), diikuti KNN (94,33%) dan SVM (89,60%), sementara Decision Tree terendah (79,68%). Hyperparameter tuning terbukti meningkatkan performa signifikan di semua algoritma, dan SHAP mengidentifikasi Weight, Height, dan Gender sebagai fitur paling berpengaruh.
Relevansi dengan Penelitian	Menggunakan dataset yang sama (UCI Obesity Dataset) dan menerapkan teknik optimasi yang serupa, yaitu hyperparameter tuning (Grid Search) dan explainability (SHAP), yang diadaptasi pada project ini melalui Permutation Importance. Algoritma yang overlap adalah KNN dan SVM; sementara paper menggunakan Logistic Regression, project ini menggantinya dengan Naive Bayes, Decision Tree, dan Random Forest untuk memperluas cakupan perbandingan algoritma.

4) Metode Optimasi yang Akan Diterapkan

Jasab:

Berdasarkan Paper

- Hyperparameter Tuning (GridSearchCV)** — mencari kombinasi parameter terbaik KNN, Naive Bayes, dan SVM secara otomatis.
- Cross-Validation (Stratified K-Fold)** — menjaga proporsi kelas seimbang di setiap fold, mengurangi bias pembagian data acak.
- Imbalance Handling (SMOTE & Random Undersampling)** — menyeimbangkan distribusi kelas agar model tidak bias ke kelas mayoritas.
- Feature Selection/Evaluation via Macro F1 Score** — GridSearchCV dioptimasi menggunakan Macro F1 (bukan Accuracy) agar performa terukur adil di semua kelas.

- e) **Explainability (SHAP)** — mengukur kontribusi setiap fitur terhadap prediksi agar model transparan dan dapat dipertanggungjawabkan (mendukung interpretasi hasil, sejalan dengan pendekatan *explainable AI* pada paper rujukan).

Tiga dari lima metode di atas (hyperparameter tuning, evaluasi berbasis metrik yang representatif, dan explainability) diadaptasi langsung dari temuan paper rujukan, sedangkan Stratified K-Fold dan penanganan imbalance ditambahkan berdasarkan karakteristik spesifik dataset obesitas pada project ini.

5) Etika dan Privasi Data

Jawab:

- Anonimisasi/masking identitas:** seluruh data berasal dari dataset publik (UCI) dan tidak memuat identitas pribadi (nama, alamat, NIK, dll.); atribut yang digunakan hanya karakteristik fisik dan gaya hidup yang telah dianonimkan sejak sumbernya.
- Pembatasan penggunaan prediksi:** hasil prediksi hanya digunakan untuk tujuan penelitian/edukasi dan deteksi dini risiko obesitas, bukan untuk kepentingan komersial atau keperluan lain di luar konteks kesehatan.
- Larangan model sebagai keputusan tunggal:** model berfungsi sebagai *decision support system*, bukan satu-satunya dasar penentuan kondisi kesehatan seseorang. Pengguna tetap disarankan berkonsultasi dengan tenaga medis profesional untuk diagnosis dan keputusan klinis final.
- Seluruh proses pengolahan data dilakukan secara bertanggung jawab, menjaga integritas data dan transparansi analisis untuk mencegah penyalahgunaan hasil prediksi.

2. SOAL AUDIT DATASET

1) Dataset yang Digunakan

Jawab:

Dataset: **Obesity Levels Dataset**

- Jumlah baris:** 2.111 (≥ 300)
- Jumlah fitur prediktor:** 16 fitur (≥ 8) — Gender, Age, Height, Weight, family_history_with_overweight, FAVC, FCVC, NCP, CAEC, SMOKE, CH2O, SCC, FAF, TUE, CALC, MTRANS
- Target:** NObeyesdad (7 kategori tingkat obesitas)

Fitur-fitur di sini berupa karakteristik fisik (Age, Height, Weight) dan gaya hidup (FCVC=konsumsi sayur, NCP=jumlah makan utama, CH2O=konsumsi air, FAF=aktivitas fisik, TUE=waktu depan layar, CAEC/CALC=kebiasaan makan/alkohol, MTRANS=moda transportasi), yang seluruhnya bersifat non-identitas dan etis digunakan untuk riset kesehatan publik.

2) Audit Data


Jawab:


Aspek	Temuan
Jumlah Baris × Kolom	2.111 baris × 17 kolom (16 fitur dan 1 target).
Tipe Data	Terdiri dari 8 kolom numerik (<i>Age</i> , <i>Height</i> , <i>Weight</i> , <i>FCVC</i> , <i>NCP</i> , <i>CH2O</i> , <i>FAF</i> , dan <i>TUE</i> ; seluruhnya bertipe float64) serta 9 kolom kategorikal (object/string), termasuk kolom target.
Distribusi Target	Distribusi kelas relatif seimbang, yaitu Obesity_Type_I = 351 , Obesity_Type_III = 324 , Obesity_Type_II = 297 , Overweight_Level_I = 290 , Overweight_Level_II = 290 , Normal_Weight = 287 , dan Insufficient_Weight = 272 .
Missing Value	Tidak ditemukan nilai yang hilang (0 missing values) pada seluruh 17 kolom sehingga dataset tergolong bersih.
Duplikat	Ditemukan 24 baris duplikat yang perlu dihapus sebelum proses pelatihan model.
Outlier (Metode IQR)	Age : 168 outlier (rentang wajar 10,87–35,08, sedangkan data aktual 14–61; usia di atas 35 tahun terdeteksi sebagai outlier secara statistik namun masih valid secara domain). NCP : 579 "outlier" karena variabel bersifat diskrit (1–4) sehingga metode IQR kurang sesuai. Height dan Weight : masing-masing hanya 1 outlier ekstrem. FCVC , CH2O , FAF , dan TUE : tidak ditemukan outlier.
Potensi Data Leakage	Fitur Weight dan Height memiliki risiko tinggi menyebabkan <i>data leakage</i> karena target NOBeyesdad pada dasarnya merupakan kategorisasi berdasarkan BMI (Weight/Height²) . Verifikasi manual menunjukkan hasil perhitungan BMI konsisten dengan label target, sehingga penggunaan kedua fitur secara langsung dapat membuat model mempelajari rumus BMI, bukan hubungan faktor gaya hidup dengan obesitas.
Class Imbalance	Ketidakseimbangan kelas tergolong ringan dengan rasio kelas terbesar terhadap terkecil sekitar 351:272 (±1,3×) . Kondisi ini tidak memerlukan SMOTE secara agresif, namun teknik SMOTE tetap diterapkan sebagai bagian dari proses optimasi untuk meningkatkan pemerataan distribusi kelas.

3) Rancangan Pipeline Preprocessing

Jawab:

Raw Data (2111 × 17)





4) Before/After Preprocessing
Jawab:

Tahap	Sebelum	Sesudah
Jumlah Baris	2.111 baris	2.087 baris (setelah menghapus 24 data duplikat)
Missing Value	Tidak terdapat missing value (0)	Tetap tidak terdapat missing value (0), karena data awal sudah bersih
Tipe Kolom Kategorikal	Bertipe teks (<i>Female/Male</i> , <i>yes/no</i> , dan kategori lainnya)	Seluruh fitur kategorikal telah dikonversi menjadi numerik menggunakan Label Encoding dan One-Hot Encoding
Skala Fitur Numerik	Memiliki rentang yang berbeda-beda, misalnya Age (14–61), Height (1,45–1,98), dan Weight (39–173)	Seluruh fitur numerik telah dinormalisasi ke rentang 0–1 menggunakan MinMaxScaler
Distribusi Target (Data Train)	Mengikuti distribusi asli dataset dengan ketidakseimbangan kelas yang relatif ringan	Distribusi kelas diseimbangkan menggunakan SMOTE (oversampling) pada data latih (<i>training set</i>), sedangkan data uji (<i>test set</i>) tetap menggunakan distribusi asli agar evaluasi model lebih realistis
Fitur Weight dan Height	Digunakan secara langsung sehingga berpotensi menimbulkan <i>data leakage</i>	Dievaluasi dalam dua skenario, yaitu (1) tetap digunakan untuk memperoleh performa maksimum dengan catatan adanya potensi <i>data leakage</i> , dan (2) dikeluarkan untuk menghasilkan model yang lebih merepresentasikan faktor gaya hidup tanpa memanfaatkan informasi BMI secara implisit.

Alasan tiap keputusan:

- **Hapus duplikat:** Menghilangkan 24 data identik untuk mencegah overfitting dan bias evaluasi akibat data yang sama muncul pada data latih maupun data uji.
- **Encoding: Label Encoding** digunakan pada fitur biner/ordinal agar urutan kategori tetap terjaga, sedangkan **One-Hot Encoding** digunakan pada fitur nominal (*MTRANS*) agar tidak terbentuk urutan yang keliru.
- **MinMaxScaler:** Menyamakan skala seluruh fitur numerik sehingga algoritma berbasis jarak seperti **KNN** dan **SVM** tidak didominasi oleh fitur dengan rentang nilai yang besar.
- **Stratified Split:** Memastikan proporsi ketujuh kelas target tetap seimbang pada data latih dan data uji.
- **SMOTE pada Data Train:** Oversampling hanya diterapkan pada data latih untuk menghindari *data leakage* dan menghasilkan evaluasi yang lebih valid.
- **Weight & Height:** Kedua fitur berpotensi menyebabkan *data leakage* karena berkaitan langsung dengan perhitungan BMI, sehingga perlu dipertimbangkan sebagai keterbatasan atau diuji pada skenario dengan dan tanpa kedua fitur tersebut.

5) Sumber Dataset, Data Dictionary, dan Batasan Penggunaan

Jawab:

- a) **Sumber dataset:** UCI Machine Learning Repository — "*Estimation of Obesity Levels Based On Eating Habits and Physical Condition*"
(<https://archive.ics.uci.edu/dataset/544/estimation+of+obesity+levels+based+on+eating+habits+and+physical+condition>)
- b) **Data dictionary (ringkas):**

Kolom	Tipe Data	Keterangan
Gender	Kategorikal	Jenis kelamin (<i>Female / Male</i>)
Age	Numerik	Usia (tahun)
Height	Numerik	Tinggi badan (meter)
Weight	Numerik	Berat badan (kg)
family_history_with_overweight	Biner	Riwayat keluarga mengalami obesitas (<i>yes/no</i>)
FAVC	Biner	Kebiasaan mengonsumsi makanan tinggi kalori (<i>yes/no</i>)
FCVC	Numerik (1–3)	Frekuensi konsumsi sayuran
NCP	Numerik (1–4)	Jumlah makan utama per hari
CAEC	Ordinal	Frekuensi konsumsi makanan di luar jam makan (<i>No, Sometimes, Frequently, Always</i>)
SMOKE	Biner	Status merokok (<i>yes/no</i>)
CH2O	Numerik (1–3)	Konsumsi air minum harian
SCC	Biner	Kebiasaan memantau konsumsi kalori (<i>yes/no</i>)
FAF	Numerik (0–3)	Frekuensi aktivitas fisik
TUE	Numerik (0–2)	Waktu penggunaan perangkat elektronik
CALC	Ordinal	Frekuensi konsumsi alkohol (<i>No, Sometimes, Frequently, Always</i>)
MTRANS	Nominal	Moda transportasi utama
NObeyesdad	Target (7 Kelas)	Kategori tingkat obesitas

3. Baseline KNN, Naive Bayes, dan SVM

1) Baseline Model — 5 Algoritma, Pipeline Sama

Jawab:

```
baseline_knn = KNeighborsClassifier()
baseline_nb = GaussianNB()
baseline_dt = DecisionTreeClassifier(random_state=42)
baseline_rf = RandomForestClassifier(random_state=42)
baseline_svm = SVC(random_state=42)
```

Kelimaanya dilatih pada input yang identik (X_train_scaled, y_train dari split & scaling yang sama), sehingga perbandingan performa murni mencerminkan karakteristik algoritma.

2) Train-Test Split Stratified + Random Seed Tetap

Jawab:

test_size=0.2, random_state=42, stratify=y_ori — rasio 80:20, **stratified** pada target NObesidad agar proporsi ke-7 kelas obesitas tetap seimbang di train maupun test, dan random_state=42 **tetap/fixed** agar pembagian data konsisten dan hasil dapat direproduksi ulang oleh siapa pun yang menjalankan notebook yang sama.

3) Parameter Awal dan Alasan Pemilihan

Jawab:

Model	Parameter Awal	Alasan Penggunaan
K-Nearest Neighbors (KNN)	n_neighbors = 5, weights = 'uniform', metrik Euclidean	Digunakan sebagai titik awal (baseline) sebelum dilakukan optimasi menggunakan GridSearchCV dengan variasi nilai n_neighbors (3, 5, 7, dan 9).
Naive Bayes	var_smoothing = 1e-9	Menggunakan parameter bawaan dari <i>scikit-learn</i> untuk mencegah terjadinya pembagian oleh varians nol.
Decision Tree	criterion = 'gini', max_depth = None, random_state = 42	Model dibiarkan tumbuh tanpa batas kedalaman sebagai baseline untuk memperoleh performa awal, kemudian dilakukan <i>hyperparameter tuning</i> guna mengurangi potensi <i>overfitting</i> .
Random Forest	n_estimators = 100, criterion = 'gini', max_depth = None, random_state = 42	Menggunakan 100 pohon sebagai nilai default yang umumnya memberikan keseimbangan antara akurasi dan waktu komputasi sebelum dilakukan optimasi parameter.
Support Vector Machine (SVM)	kernel = 'rbf', C = 1.0, gamma = 'scale'	Kernel RBF dipilih untuk menangani pola nonlinier, sedangkan C = 1.0 digunakan sebagai nilai awal yang memberikan keseimbangan antara margin dan tingkat kesalahan klasifikasi.

4) Evaluasi Model

Jawab:

Ranking performa: SVM > Random Forest > Decision Tree > KNN > Naive Bayes.

Confusion matrix (sudah dibangkitkan di notebook untuk kelima model): pola kesalahan pada SVM, RF, dan DT terkonsentrasi pada kelas-kelas bertetangga secara BMI (Overweight Level I↔II, Obesity Type I↔II). Decision Tree menunjukkan sedikit lebih banyak kesalahan dibanding RF karena rawan overfit pada cabang-cabang spesifik (single tree, tanpa *bagging*). KNN dan Naive Bayes menyebar lebih luas ke banyak kelas.

5) Karakteristik Model

Jawab:

- a) **Scaling:** KNN dan SVM sangat sensitif terhadap skala fitur sehingga memerlukan **MinMaxScaler**, sedangkan **Decision Tree** dan **Random Forest** tidak karena menggunakan pemisahan berdasarkan *threshold*, bukan jarak.
- b) **Naive Bayes:** Mengasumsikan fitur saling independen dan berdistribusi Gaussian. Asumsi ini kurang sesuai dengan dataset karena terdapat korelasi antarfitur (misalnya **Weight–Height**), sehingga performanya cenderung lebih rendah.
- c) **Kompleksitas Komputasi:** Naive Bayes, KNN, dan **Decision Tree** memiliki waktu pelatihan paling cepat. **Random Forest** lebih lambat karena membangun banyak pohon, sedangkan SVM paling lambat akibat proses optimasi kernel yang lebih kompleks.
- d) **Interpretabilitas:** **Decision Tree** paling mudah dijelaskan, **Random Forest** dapat dianalisis melalui *feature importance*, **Naive Bayes** melalui probabilitas, KNN berdasarkan tetangga terdekat, sedangkan SVM merupakan model yang paling sulit diinterpretasikan tanpa bantuan metode seperti SHAP.

4. Optimasi Perbandingan Model dan Analisis Eksperimen

1) Tiga Strategi Optimasi yang Digunakan

Jawab:

Project ini sudah menerapkan 3 strategi optimasi:

- a) **Hyperparameter Tuning:** via GridSearchCV untuk kelima model.
- b) **Cross-Validation:** StratifiedKFold(n_splits=5, shuffle=True, random_state=42), digunakan sebagai validator internal di dalam GridSearchCV agar setiap fold tetap proporsional terhadap 7 kelas target.
- c) **Class Imbalance Handling:** SMOTE (oversampling) dan Random Undersampling, diuji sebagai skenario data terpisah ("Data Ori Over", "Data Ori Under") untuk melihat pengaruhnya terhadap performa tiap model.

2) GridSearchCV dengan Scoring Macro-F1

Jawab:

Seluruh proses tuning menggunakan scoring='f1_macro' (bukan accuracy), agar performa terukur adil di ketujuh kelas — penting karena beberapa kelas (Insufficient_Weight, Normal_Weight) punya jumlah sampel lebih kecil dibanding Obesity_Type_I. Grid parameter yang diuji:

Model	Grid Hyperparameter yang Diuji
K-Nearest Neighbors (KNN)	n_neighbors: [3, 5, 7, 9]; weights: ['uniform', 'distance']
Decision Tree	max_depth: [None, 10, 20, 30]; min_samples_split: [2, 5, 10]; min_samples_leaf: [1, 2, 4]
Naive Bayes	var_smoothing: [1e-9, 1e-8, 1e-7, 1e-6, 1e-5]
Random Forest	n_estimators: [100, 200, 300]; max_depth: [None, 10, 20]; min_samples_split: [2, 5]; min_samples_leaf: [1, 2]
Support Vector Machine (SVM)	C: [0.1, 1, 10, 100]; kernel: ['linear', 'rbf', 'poly']; gamma: ['scale', 'auto']

3) Tabel Baseline vs Optimized

a) Data Original

- KNN

	Dataset	Model	Accuracy	Precision	Recall	Macro F1	Balanced Accuracy
0	Original	Baseline	0.789598	0.783741	0.786224	0.780381	0.786224
1	Original	Optimized	0.817967	0.811380	0.814836	0.809025	0.814836
2	Undersampling	Baseline	0.761229	0.756391	0.759201	0.750881	0.759201
3	Undersampling	Optimized	0.808511	0.803134	0.805406	0.799536	0.805406
4	SMOTE	Baseline	0.789598	0.782045	0.786306	0.780568	0.786306
5	SMOTE	Optimized	0.817967	0.813581	0.815358	0.808208	0.815358

- Decision Tree

	Dataset	Model	Accuracy	Precision	Recall	Macro F1	Balanced Accuracy
0	Original	Baseline	0.926714	0.928255	0.922798	0.924643	0.922798
1	Original	Optimized	0.919622	0.921331	0.915408	0.917073	0.915408
2	Undersampling	Baseline	0.917258	0.916708	0.913972	0.914647	0.913972
3	Undersampling	Optimized	0.910165	0.908339	0.907005	0.907386	0.907005
4	SMOTE	Baseline	0.914894	0.916039	0.910987	0.912761	0.910987
5	SMOTE	Optimized	0.914894	0.916039	0.910987	0.912761	0.910987

- Naïve Bayes

	Dataset	Model	Accuracy	Precision	Recall	Macro F1	Balanced Accuracy
0	Original	Baseline	0.612293	0.654025	0.609499	0.595211	0.609499
1	Original	Optimized	0.612293	0.654025	0.609499	0.595211	0.609499
2	Undersampling	Baseline	0.612293	0.644617	0.609341	0.593653	0.609341
3	Undersampling	Optimized	0.612293	0.644617	0.609341	0.593653	0.609341
4	SMOTE	Baseline	0.614657	0.657012	0.612220	0.593318	0.612220
5	SMOTE	Optimized	0.614657	0.657012	0.612220	0.593318	0.612220

- Random Forest

	Dataset	Model	Accuracy	Precision	Recall	Macro F1	Balanced Accuracy
0	Original	Baseline	0.947991	0.952842	0.945935	0.947345	0.945935
1	Original	Optimized	0.947991	0.953330	0.945935	0.947199	0.945935
2	Undersampling	Baseline	0.943262	0.947905	0.942036	0.942657	0.942036
3	Undersampling	Optimized	0.936170	0.941126	0.934464	0.935332	0.934464
4	SMOTE	Baseline	0.943262	0.947698	0.941009	0.942579	0.941009
5	SMOTE	Optimized	0.943262	0.946479	0.941191	0.942044	0.941191

- SVM

	Dataset	Model	Accuracy	Precision	Recall	Macro F1	Balanced Accuracy
0	Original	Baseline	0.820331	0.816262	0.818344	0.816508	0.818344
1	Original	Optimized	0.950355	0.950455	0.949311	0.949297	0.949311
2	Undersampling	Baseline	0.810875	0.807113	0.809758	0.807153	0.809758
3	Undersampling	Optimized	0.952719	0.952024	0.951774	0.951274	0.951774
4	SMOTE	Baseline	0.822695	0.820064	0.821652	0.819762	0.821652
5	SMOTE	Optimized	0.955083	0.955933	0.954237	0.954441	0.954237

b) Data Clean

- KNN

	Dataset	Model	Accuracy	Precision	Recall	Macro F1	Balanced Accuracy
0	Cleaning	Baseline	0.762590	0.727303	0.731659	0.724529	0.731659
1	Cleaning	Optimized	0.794964	0.771170	0.773516	0.767259	0.773516
2	Undersampling	Baseline	0.758993	0.717750	0.730952	0.716428	0.730952
3	Undersampling	Optimized	0.794964	0.754915	0.775033	0.757345	0.775033
4	SMOTE	Baseline	0.791367	0.764774	0.764777	0.760492	0.764777
5	SMOTE	Optimized	0.798561	0.770651	0.776839	0.768654	0.776839

- Decision Tree

	Dataset	Model	Accuracy	Precision	Recall	Macro F1	Balanced Accuracy
0	Cleaning	Baseline	0.924460	0.911512	0.912528	0.911532	0.912528
1	Cleaning	Optimized	0.917266	0.904873	0.902324	0.903183	0.902324
2	Undersampling	Baseline	0.935252	0.924159	0.924616	0.924127	0.924616
3	Undersampling	Optimized	0.938849	0.928428	0.928818	0.928263	0.928818
4	SMOTE	Baseline	0.956835	0.949963	0.950231	0.949873	0.950231
5	SMOTE	Optimized	0.956835	0.949963	0.950231	0.949873	0.950231

- Naïve Bayes

	Dataset	Model	Accuracy	Precision	Recall	Macro F1	Balanced Accuracy
0	Cleaning	Baseline	0.571942	0.467723	0.498064	0.407310	0.498064
1	Cleaning	Optimized	0.672662	0.710706	0.614671	0.595452	0.614671
2	Undersampling	Baseline	0.579137	0.553353	0.492544	0.458231	0.492544
3	Undersampling	Optimized	0.651079	0.700167	0.579869	0.576827	0.579869
4	SMOTE	Baseline	0.600719	0.763461	0.534060	0.464047	0.534060
5	SMOTE	Optimized	0.708633	0.725982	0.655817	0.645633	0.655817

- Random Forest

	Dataset	Model	Accuracy	Precision	Recall	Macro F1	Balanced Accuracy
0	Cleaning	Baseline	0.949640	0.947039	0.937092	0.940285	0.937092
1	Cleaning	Optimized	0.949640	0.949155	0.935653	0.940099	0.935653
2	Undersampling	Baseline	0.938849	0.931606	0.926641	0.928304	0.926641
3	Undersampling	Optimized	0.946043	0.940201	0.935605	0.937327	0.935605
4	SMOTE	Baseline	0.956835	0.959529	0.944956	0.949478	0.944956
5	SMOTE	Optimized	0.956835	0.959529	0.944956	0.949478	0.944956

- SVM

	Dataset	Model	Accuracy	Precision	Recall	Macro F1	Balanced Accuracy
0	Cleaning	Baseline	0.827338	0.803625	0.798550	0.800474	0.798550
1	Cleaning	Optimized	0.964029	0.957051	0.960974	0.957957	0.960974
2	Undersampling	Baseline	0.791367	0.759058	0.761403	0.759232	0.761403
3	Undersampling	Optimized	0.935252	0.922959	0.925879	0.923385	0.925879
4	SMOTE	Baseline	0.841727	0.820234	0.815718	0.817329	0.815718
5	SMOTE	Optimized	0.935252	0.921394	0.924417	0.922282	0.924417

4) Error Analysis

Jawab:

- Pola kelas yang sering keliru:** berdasarkan confusion matrix di notebook, kesalahan terkonsentrasi pada **pasangan kelas yang bertetangga secara BMI** — *Overweight_Level_I* ↔ *Overweight_Level_II* dan *Obesity_Type_I* ↔ *Obesity_Type_II*. Ini konsisten di semua model, termasuk SVM yang paling akurat.
- Contoh pola prediksi benar:** individu dengan Weight/Height jauh dari ambang batas kelas (mis. BMI sangat tinggi → *Obesity_Type_III*) hampir selalu terklasifikasi benar oleh SVM dan RF, karena jaraknya ke batas keputusan besar.
- Contoh pola prediksi salah:** individu dengan BMI tepat di sekitar ambang batas dua kelas (mis. BMI≈27, batas *Overweight_Level_I/II*) rawan terklasifikasi ke kelas tetangganya — **penyebabnya:** batas antar level obesitas pada dataset ini bersifat kontinu (fungsi BMI), sementara model klasifikasi harus membuat

keputusan diskrit tegas, sehingga titik-titik di sekitar ambang batas inherently ambigu.

- d) **Naive Bayes** menunjukkan kesalahan paling menyebar ke banyak kelas sekaligus (bukan hanya kelas tetangga) — mengonfirmasi bahwa penyebabnya bukan sekadar batas BMI, melainkan **pelanggaran asumsi independensi fitur** (Weight-Height, FCVC-FAVC saling berkorelasi), membuat estimasi probabilitasnya kurang andal di seluruh kelas.

5) Model Terbaik

Jawab:

Keputusan: SVM (C=100, kernel linear) dipilih sebagai model produksi, karena performa **tertinggi** (akurasi 0,9640 dan F1-Macro 0,9580 pada skenario Data Cleaning — hasil terbaik project ini) dengan stabilitas cross-validation yang baik. Trade-off-nya adalah interpretabilitas rendah, namun ini **dimitigasi dengan SHAP** (sudah direncanakan pada strategi optimasi Soal 01), sehingga kelemahan interpretabilitas dapat diatasi tanpa mengorbankan performa. **Random Forest menjadi kandidat kedua** yang solid — performa hampir setara SVM, stabilitas CV bahkan sedikit lebih baik, dan interpretabilitas lebih mudah lewat feature importance — cocok sebagai model pembanding/*sanity check* dalam laporan.

5. Aplikasi UI/UX, Laporan Akhir, Portofolio, dan Verifikasi Lisan

1) Aplikasi Web — Streamlit

Jawab:

- a) **Dashboard Data** — kartu metrik ringkasan dataset (total baris, kolom fitur, dll.) + visualisasi EDA
- b) **Prediktor Tingkat Obesitas** — form input profil fisik & gaya hidup, menghasilkan prediksi kelas + grafik probabilitas per kelas
- c) **Perbandingan Eksperimen** — visualisasi metrik dari perbandingan 5 model $\times$ 6 skenario preprocessing
- d) **Interpretasi Model** — penjelasan kontribusi fitur terhadap prediksi model terbaik (Permutation Importance)

2) UI/UX — Light, Rapi, Etis

Jawab:

- a) Font **Poppins** via Google Fonts, warna brand **#ED2B07** sebagai aksen (gradient header, dsb.)
- b) Layout kolom (st.columns) untuk kerapian form, kartu metrik bergaya metric-card
- c) Bahasa Indonesia konsisten, kalimat prediksi ditulis etis: *"...untuk memprediksi tingkat obesitas beserta probabilitas kemunculannya secara etis"* — sudah menghindari framing seolah hasil adalah diagnosis final

- d) Responsivitas mengandalkan grid columns Streamlit (built-in responsive di breakpoint standar)

3) **Backend Modular** — sudah terpisah rapi di folder Src/:

Jawab:

File	Peran
train.py	Melakukan proses pelatihan (<i>training</i>) model machine learning.
ml_core.py	Berisi logika utama machine learning, termasuk <i>preprocessing</i> dan <i>pipeline</i> pemodelan.
predict.py	Menangani proses prediksi (<i>inference</i>), termasuk fungsi <code>preprocess_input()</code> dan <code>scale_input()</code> yang digunakan oleh aplikasi.
data_generator.py	Menyiapkan dan menghasilkan data yang digunakan dalam proses pelatihan maupun pengujian.
Models/model_terbaik.joblib & Models/scaler_minmax.joblib	Menyimpan model terbaik dan objek <i>MinMaxScaler</i> yang kemudian dimuat kembali menggunakan fungsi <code>get_cached_model()</code> .

4) **Kelengkapan Deliverable**

Jawab:

uas-ml-obesity-A11.2024.15547-A11.4410-Tegar Scaesario/

— Data/	→ Dataset + Data Dictionary + Sumber Data
— Models/	→ Model terbaik (.joblib) + Scaler (.joblib)
— Notebook/	→ Notebook eksplorasi, preprocessing, training, evaluasi
— Presentation/	→ Materi presentasi UAS (PDF)
— Report/	→ Laporan akademik lengkap (PDF)
— Reports/	→ Hasil eksperimen (CSV), audit dataset (JSON), classification report (JSON)
— Src/	→ Backend modular
— app_streamlit.py	→ Dashboard interaktif
— api_fastapi.py	→ REST API
— Dockerfile + docker-compose.yml	→ Containerisasi
— requirements.txt	→ Dependensi
— readme.md	→ Dokumentasi project
— Lembar Jawab-15547.pdf	→ Jawaban UAS
— Paper.pdf	→ Paper rujukan (mini-review)

5) **Presentasi**

Jawab:

Link video presentasi:

https://drive.google.com/drive/folders/1mQ3qgV8gsEzcwnxQ2hwm05ehSzXwQGpb?usp=drive_link