

**LAPORAN AKADEMIK UAS  
PEMBELAJARAN MESIN A11.4410**



**Dosen Pengampu:**

**Junta Zeniarja, M.Kom**

**Disusun Oleh:**

**Tegar Scasario ( A11.2024.15547)**

**PROGRAM STUDI SARJANA TEKNIK INFORMATIKA  
FAKULTAS ILMU KOMPUTER  
UNIVERSITAS DIAN NUSWANTORO  
2026**

# **BAB I**

## **PENDAHULUAN**

### **1.1 Latar Belakang Masalah**

Obesitas bukan lagi sekadar persoalan penampilan fisik, melainkan salah satu tantangan kesehatan masyarakat paling serius pada abad ini. Data yang dirujuk dalam berbagai studi terbaru menunjukkan bahwa sejak tahun 1975 angka obesitas global meningkat hampir tiga kali lipat, dengan lebih dari 1,9 miliar orang saat ini tergolong kelebihan berat badan dan sekitar 650 juta di antaranya mengalami obesitas (Shafi et al., 2026). Kondisi ini tidak berdiri sendiri — obesitas berkontribusi besar terhadap munculnya penyakit kardiovaskular, hipertensi, diabetes tipe 2, gangguan sendi, hingga gangguan psikologis seperti rendahnya kepercayaan diri dan stigma sosial. Yang membuat persoalan ini semakin kompleks adalah penyebabnya yang multifaktorial: faktor genetik, pola makan, aktivitas fisik, kondisi sosial-ekonomi, dan gaya hidup saling berinteraksi membentuk risiko obesitas pada tiap individu.

Pendekatan konvensional untuk menilai risiko obesitas — seperti perhitungan Body Mass Index (BMI) atau pengukuran lingkar pinggang — memang sederhana dan mudah diterapkan, tetapi memiliki keterbatasan mendasar. Ukuran-ukuran ini bersifat linier dan tidak mampu menangkap interaksi non-linear antar variabel gaya hidup yang sebenarnya ikut menentukan tingkat obesitas seseorang. Di sinilah pendekatan machine learning menjadi relevan: algoritma klasifikasi seperti K-Nearest Neighbors (KNN), Naive Bayes, dan Support Vector Machine (SVM) memungkinkan sistem mempelajari pola dari data kebiasaan hidup — mulai dari frekuensi konsumsi sayur, kebiasaan ngemil, tingkat aktivitas fisik, hingga moda transportasi harian — untuk memprediksi tingkat obesitas seseorang secara lebih akurat dibandingkan metode konvensional.

Berangkat dari kebutuhan tersebut, project ini dikembangkan sebagai upaya membangun sistem klasifikasi tingkat obesitas berbasis machine learning, sekaligus membungkusnya dalam sebuah dashboard interaktif berbasis Streamlit agar hasil prediksi dan interpretasi model dapat diakses dan dipahami secara langsung oleh pengguna non-teknis, misalnya tenaga kesehatan atau individu yang ingin melakukan skrining awal terhadap risiko obesitasnya.

## 1.2 Tujuan Project

Secara umum, project ini bertujuan untuk:

- a) Membangun model klasifikasi machine learning yang mampu memprediksi tingkat obesitas seseorang (Insufficient Weight hingga Obesity Type III) berdasarkan atribut demografis, kebiasaan makan, dan gaya hidup.
- b) Membandingkan performa beberapa algoritma klasifikasi — KNN, Naive Bayes, dan SVM — pada beberapa skenario penanganan data (data asli, undersampling, dan oversampling/SMOTE) untuk menentukan model dengan performa terbaik.
- c) Melakukan audit dan preprocessing data secara sistematis, mencakup penanganan missing value, duplikasi, outlier, encoding variabel kategorik, scaling, serta pemeriksaan potensi data leakage dan class imbalance.
- d) Mengimplementasikan hasil model ke dalam sebuah aplikasi dashboard interaktif yang tidak hanya menampilkan hasil prediksi, tetapi juga interpretasi model (feature importance) agar keputusan model dapat dipertanggungjawabkan secara akademik maupun etis.
- e) Menyusun laporan akademik yang mendokumentasikan keseluruhan proses penelitian, mulai dari studi literatur, eksperimen, hingga hasil dan pembahasan, sebagai bentuk pertanggungjawaban ilmiah atas project yang dikerjakan.

## BAB II STUDI LITERATUR

### 2.1 Mini-Review Paper

| Komponen                   | Uraian                                                                                                                                                                                                                                                                                                                                                                                                               |
|----------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Penulis                    | Salliah Shafi, Gufran Ahmad Ansari, Lamees Alhazaa                                                                                                                                                                                                                                                                                                                                                                   |
| Tahun                      | 2026                                                                                                                                                                                                                                                                                                                                                                                                                 |
| Jurnal                     | <i>Systems and Soft Computing</i> (Elsevier), Vol. 8, Artikel 200472                                                                                                                                                                                                                                                                                                                                                 |
| DOI                        | 10.1016/j.sasc.2026.200472                                                                                                                                                                                                                                                                                                                                                                                           |
| Judul Paper                | <i>Optimizing machine learning models for obesity risk prediction through hyperparameter tuning</i>                                                                                                                                                                                                                                                                                                                  |
| Dataset                    | UCI Obesity Levels Dataset (2.111 baris, 17 atribut, dari UCI Machine Learning Repository)                                                                                                                                                                                                                                                                                                                           |
| Metode                     | Logistic Regression, SVM, KNN, Decision Tree; optimasi hyperparameter menggunakan Grid Search dan Random Search; feature engineering berbasis algoritma Cuckoo Search; interpretasi model menggunakan SHAP.                                                                                                                                                                                                          |
| Metrik Evaluasi            | Accuracy, Precision, Recall, F1-Score                                                                                                                                                                                                                                                                                                                                                                                |
| Hasil Utama                | Logistic Regression memperoleh akurasi tertinggi sebesar <b>99,63%</b> , diikuti <b>KNN (94,33%)</b> , <b>SVM (89,60%)</b> , dan <b>Decision Tree (79,68%)</b> . Hyperparameter tuning meningkatkan performa seluruh model, sedangkan SHAP menunjukkan bahwa <b>berat badan, tinggi badan, dan jenis kelamin</b> merupakan fitur yang paling berpengaruh terhadap prediksi risiko obesitas.                          |
| Relevansi terhadap Project | Menggunakan dataset yang sama, yaitu <b>UCI Obesity Levels Dataset</b> , serta menguji dua algoritma yang digunakan dalam project ( <b>KNN dan SVM</b> ). Paper ini juga menjadi referensi dalam penerapan <b>hyperparameter tuning</b> (Grid Search dan Random Search), <b>cross-validation</b> , <b>feature selection</b> , serta <b>explainable AI (SHAP)</b> untuk meningkatkan performa dan interpretasi model. |

### 2.2 Sintesis Metode Optimasi yang Diadaptasi

Berdasarkan bukti empiris dari paper di atas, project ini menurunkan lima strategi optimasi berikut untuk diuji pada algoritma wajib (KNN, Naive Bayes, SVM):

- Hyperparameter tuning melalui Grid Search / Randomized Search.**  
Paper menunjukkan bahwa performa keempat model naik signifikan setelah tuning — misalnya penyesuaian regularisasi pada model linear dan konfigurasi kernel/gamma pada SVM. Strategi ini diadaptasi menggunakan

GridSearchCV untuk mencari kombinasi parameter *n\_neighbors/metric* pada KNN, *var\_smoothing* pada Naive Bayes, dan *kernel/C/gamma* pada SVM.

- b) **Cross-validation (k-fold).** Paper menggunakan *10-fold cross-validation* untuk memastikan hasil tidak bias terhadap satu pembagian data tertentu. Project ini mengadopsi *stratified k-fold cross-validation* agar proporsi tiap kelas obesitas tetap terjaga di setiap fold, mengingat distribusi kelas pada dataset obesitas tidak sepenuhnya seimbang.
- c) **Feature engineering / feature selection.** Paper mengusulkan *Cuckoo Search* — algoritma metaheuristik berbasis perilaku parasitisme induk burung kukuk — untuk menyeleksi subset fitur paling relevan. Karena kompleksitas algoritma Cuckoo Search berada di luar cakupan wajib project ini, prinsipnya diadaptasi dalam bentuk yang lebih sederhana dan tetap dapat dipertanggungjawabkan secara akademik, yaitu seleksi fitur berbasis *korelasi* dan *mutual information* terhadap variabel target.
- d) **Penanganan class imbalance.** Meskipun paper tidak secara eksplisit membahas *imbalance handling*, distribusi tujuh kelas target (*Insufficient Weight* hingga *Obesity Type III*) pada dataset yang sama diketahui tidak sepenuhnya rata. Project ini menambahkan strategi *oversampling* (SMOTE) sebagai perluasan dari metodologi paper, sejalan dengan anjuran lembar soal UAS.
- e) **Explainability (interpretasi model).** Paper menggunakan SHAP untuk mengidentifikasi kontribusi tiap fitur terhadap prediksi, dan menemukan berat badan serta tinggi badan sebagai fitur paling dominan — sesuai ekspektasi karena keduanya komponen penyusun BMI. Project ini mengadaptasi prinsip yang sama secara lebih ringan menggunakan *feature importance* dari model berbasis pohon sebagai pembanding, serta analisis kesalahan (*error analysis*) untuk melengkapi interpretasi pada model KNN dan SVM yang secara alami kurang *interpretable*.

## BAB III DATASET DAN DATA DICTIONARY

### 3.1 Sumber Data

Dataset yang digunakan pada project ini adalah **Obesity Levels Dataset** yang bersumber dari UCI Machine Learning Repository, dengan nama file ObesityDataSet\_raw\_and\_data\_synthetic.csv sebagaimana sudah digunakan pada modul get\_dataset() di aplikasi dashboard. Dataset ini merupakan dataset publik yang juga menjadi rujukan pada paper utama (Shafi et al., 2026) yang dibahas pada Bab 2, sehingga hasil eksperimen pada project ini dapat dibandingkan secara langsung dengan hasil yang dilaporkan pada literatur.

Dataset terdiri atas **2.111 baris data** dan **17 atribut** (16 fitur prediktor + 1 target), mencakup kombinasi data survei asli terhadap individu di Meksiko, Peru, dan Kolombia, serta data sintetis yang dihasilkan menggunakan teknik SMOTE oleh penyusun dataset aslinya untuk menyeimbangkan proporsi kelas — sebuah detail penting yang perlu diperhitungkan pada tahap audit data di Bab 4, karena memengaruhi interpretasi terhadap keaslian pola statistik dalam dataset.

#### Cara memperoleh dataset:

<https://archive.ics.uci.edu/dataset/544/estimation+of+obesity+levels+based+on+eating+habits+and+physical+condition>

kemudian disimpan pada direktori **Data/** sesuai struktur folder aplikasi.

### 3.2 Data Dictionary

| No | Nama Atribut                   | Tipe Data | Deskripsi                                              | Rentang / Nilai Kategori |
|----|--------------------------------|-----------|--------------------------------------------------------|--------------------------|
| 1  | Gender                         | Kategorik | Jenis kelamin biologis individu                        | Male / Female            |
| 2  | Age                            | Numerik   | Usia individu (tahun)                                  | 14 – 61                  |
| 3  | Height                         | Numerik   | Tinggi badan (meter)                                   | 1,45 – 1,98              |
| 4  | Weight                         | Numerik   | Berat badan (kilogram)                                 | 39 – 173                 |
| 5  | family_history_with_overweight | Kategorik | Riwayat kelebihan berat badan pada anggota keluarga    | Yes / No                 |
| 6  | FAVC                           | Kategorik | Kebiasaan konsumsi makanan tinggi kalori secara sering | Yes / No                 |

|           |                     |                        |                                              |                                                                                                                                      |
|-----------|---------------------|------------------------|----------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------|
| <b>7</b>  | FCVC                | Numerik<br>(Ordinal)   | Frekuensi konsumsi sayur                     | 1–3 (1 = Tidak pernah, 2 = Kadang, 3 = Selalu)                                                                                       |
| <b>8</b>  | NCP                 | Numerik<br>(Ordinal)   | Jumlah makan utama per hari                  | 1–4                                                                                                                                  |
| <b>9</b>  | CAEC                | Kategorik              | Kebiasaan ngemil di luar jam makan utama     | No / Sometimes / Frequently / Always                                                                                                 |
| <b>10</b> | SMOKE               | Kategorik              | Kebiasaan merokok                            | Yes / No                                                                                                                             |
| <b>11</b> | CH2O                | Numerik<br>(Ordinal)   | Konsumsi air putih harian                    | 1–3 (1 = <1 L, 2 = 1–2 L, 3 = >2 L)                                                                                                  |
| <b>12</b> | SCC                 | Kategorik              | Kebiasaan memonitor asupan kalori harian     | Yes / No                                                                                                                             |
| <b>13</b> | FAF                 | Numerik<br>(Ordinal)   | Frekuensi aktivitas fisik mingguan           | 0–3 (0 = Tidak pernah, 3 = Sangat sering)                                                                                            |
| <b>14</b> | TUE                 | Numerik<br>(Ordinal)   | Waktu penggunaan perangkat elektronik harian | 0–2 (0 = <2 jam, 1 = 3–5 jam, 2 = >5 jam)                                                                                            |
| <b>15</b> | CALC                | Kategorik              | Frekuensi konsumsi alkohol                   | No / Sometimes / Frequently / Always                                                                                                 |
| <b>16</b> | MTRANS              | Kategorik              | Moda transportasi utama sehari-hari          | Automobile / Motorbike / Bike / Public_Transportation / Walking                                                                      |
| <b>17</b> | NObeyesdad (Target) | Kategorik<br>(7 Kelas) | Kategori tingkat obesitas individu           | Insufficient Weight / Normal Weight / Overweight Level I / Overweight Level II / Obesity Type I / Obesity Type II / Obesity Type III |

### 3.3 Definisi Target Klasifikasi

Target prediksi (NObayesdad) merupakan variabel kategorik dengan **tujuh kelas**, sehingga permasalahan ini secara ilmiah tergolong **supervised multi-class classification**, bukan regresi maupun klastering. Alasannya:

- a) Label target bersifat **diskret dan telah diketahui** pada data latih (bukan nilai kontinu seperti pada regresi), sehingga pendekatan klasifikasi lebih tepat dibanding regresi.
- b) Tujuan project adalah **memetakan input ke kategori yang sudah ditentukan sebelumnya** (tujuh tingkat obesitas), bukan mengelompokkan data tanpa label acuan seperti pada klastering (*unsupervised learning*).
- c) Ketujuh kelas target memiliki **urutan tingkat keparahan yang implisit** (dari *Insufficient Weight* hingga *Obesity Type III*), namun pada project ini tetap diperlakukan sebagai klasifikasi nominal multi-kelas mengingat KNN, Naive Bayes, dan SVM yang diwajibkan pada lembar soal secara default bekerja sebagai *classifier* nominal, bukan *ordinal classifier*.

### 3.4 Etika dan Privasi Data

Beberapa hal terkait etika penggunaan data ditetapkan sebagai berikut:

- a) **Anonimitas terjaga.** Dataset UCI Obesity tidak memuat identitas pribadi (nama, alamat, nomor identitas) apa pun — seluruh baris data hanya berisi atribut fisik dan gaya hidup yang telah dianonimkan sejak sumber aslinya, sehingga tidak ada risiko identifikasi ulang individu (*re-identification*).
- b) **Sensitivitas atribut kesehatan.** Meskipun teranonimkan, atribut seperti berat badan, tinggi badan, dan kebiasaan hidup tergolong data yang berkaitan dengan kondisi kesehatan seseorang. Oleh karena itu, project ini memperlakukan seluruh data sebagai data sensitif dan tidak menyimpan input pengguna aplikasi (form prediksi pada dashboard) ke penyimpanan permanen mana pun — prediksi dihitung secara *on-the-fly* dan tidak direkam.
- c) **Larangan penyalahgunaan hasil prediksi.** Aplikasi secara eksplisit mencantumkan disclaimer pada hasil prediksi ("*Gunakan hasil ini sebagai referensi awal. Harap konsultasikan dengan dokter atau ahli gizi profesional...*") untuk mencegah penggunaan hasil model sebagai diagnosis medis final.

### 3.5 Batasan Penggunaan Data dan Model

- a) Dataset **hanya digunakan untuk kepentingan akademik** (tugas UAS mata kuliah Pembelajaran Mesin) dan pengembangan purwarupa



aplikasi, bukan untuk produksi klinis atau pengambilan keputusan kesehatan nyata.

- b) Model yang dihasilkan **berfungsi sebagai alat bantu deteksi dini (*decision support*)**, sejalan dengan catatan penilaian OBE pada lembar soal UAS yang menegaskan bahwa aplikasi tidak boleh diklaim sebagai alat keputusan final.

## BAB IV

### AUDIT DATA DAN PREPROCESSING

#### 4.1 Audit Kualitas Data Awal

a) Ringkasan Audit Dataset Mentah

| Aspek                                 | Hasil                                                                       |
|---------------------------------------|-----------------------------------------------------------------------------|
| Jumlah baris                          | 2.111                                                                       |
| Jumlah kolom                          | 17 (16 fitur + 1 target)                                                    |
| Tipe data                             | 8 kolom numerik ( <i>float64</i> ), 9 kolom kategorik ( <i>string/str</i> ) |
| Missing value                         | 0 pada seluruh kolom (dataset bersih dari nilai kosong)                     |
| Data duplikat                         | 24 baris identik pada seluruh 17 kolom                                      |
| Baris mengandung outlier (metode IQR) | 702 baris (33,3% dari total data)                                           |

b) Deteksi Outlier per Kolom Numerik

| Kolom                                       | Jumlah Outlier |
|---------------------------------------------|----------------|
| NCP (Jumlah makan utama per hari)           | 579            |
| Age (Usia)                                  | 168            |
| Height (Tinggi badan)                       | 1              |
| Weight (Berat badan)                        | 1              |
| FCVC (Frekuensi konsumsi sayur)             | 0              |
| CH2O (Konsumsi air putih harian)            | 0              |
| FAF (Frekuensi aktivitas fisik)             | 0              |
| TUE (Waktu penggunaan perangkat elektronik) | 0              |

#### 4.2 Pembersihan Duplikat dan Outlier

c. Hapus Data duplikat dan Outlier

```
data_clean = data.drop_duplicates()
print("\nJumlah Data Setelah Menghapus Duplikat:", len(data_clean))

numerical_cols = data_clean.select_dtypes(include=['int64', 'float64']).columns
Q1 = data_clean[numerical_cols].quantile(0.25)
Q3 = data_clean[numerical_cols].quantile(0.75)
IQR = Q3 - Q1
outlier_mask = ((data_clean[numerical_cols] < (Q1 - 1.5 * IQR)) | (data_clean[numerical_cols] >
(Q3 + 1.5 * IQR))).any(axis=1)

data_clean = data_clean[~outlier_mask]
print("\nJumlah Data Setelah Menghapus Outlier:", len(data_clean))

data_clean
```

Python

Jumlah Data Setelah Menghapus Duplikat: 2087

Jumlah Data Setelah Menghapus Outlier: 1388

| Kolom                                 | Jenis Encoding | Mapping                                                                                                                                                    |
|---------------------------------------|----------------|------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Gender</b>                         | Nominal        | Female = 0, Male = 1                                                                                                                                       |
| <b>family_history_with_overweight</b> | Biner          | No = 0, Yes = 1                                                                                                                                            |
| <b>FAVC</b>                           | Biner          | No = 0, Yes = 1                                                                                                                                            |
| <b>SMOKE</b>                          | Biner          | No = 0, Yes = 1                                                                                                                                            |
| <b>SCC</b>                            | Biner          | No = 0, Yes = 1                                                                                                                                            |
| <b>CAEC</b>                           | Ordinal        | No = 0, Sometimes = 1, Frequently = 2, Always = 3                                                                                                          |
| <b>CALC</b>                           | Ordinal        | No = 0, Sometimes = 1, Frequently = 2, Always = 3                                                                                                          |
| <b>MTRANS</b>                         | Nominal        | Walking = 0, Bike = 1, Public_Transportation = 2, Motorbike = 3, Automobile = 4                                                                            |
| <b>NObeyesdad (Target)</b>            | Ordinal        | Insufficient_Weight = 0, Normal_Weight = 1, Overweight_Level_I = 2, Overweight_Level_II = 3, Obesity_Type_I = 4, Obesity_Type_II = 5, Obesity_Type_III = 6 |

Total baris yang hilang dari proses pembersihan mencapai **699 dari 2.111 baris awal (34,3%)** — proporsi yang cukup besar.

#### 4.3 Encoding Data Kategorik

Sembilan kolom kategorik dikonversi menjadi numerik menggunakan **label encoding manual** (mapping eksplisit), bukan `LabelEncoder()` otomatis dari `scikit-learn`, sehingga urutan encoding dapat dikontrol penuh dan bersifat *ordinal-aware* untuk atribut yang memang berjenjang.

#### 4.4 Pemeriksaan Class Imbalance

Distribusi kelas target diperiksa baik pada data asli maupun data hasil pembersihan, untuk melihat dampak proses cleaning terhadap keseimbangan kelas.

| Kelas                          | Data Asli (n = 2.111) | Data Bersih (n = 1.388) | Perubahan |
|--------------------------------|-----------------------|-------------------------|-----------|
| <b>0 – Insufficient Weight</b> | 272                   | 141                     | –48,2%    |
| <b>1 – Normal Weight</b>       | 287                   | 196                     | –31,7%    |
| <b>2 – Overweight Level I</b>  | 290                   | 148                     | –49,0%    |
| <b>3 – Overweight Level II</b> | 290                   | 170                     | –41,4%    |
| <b>4 – Obesity Type I</b>      | 351                   | 194                     | –44,7%    |
| <b>5 – Obesity Type II</b>     | 297                   | 216                     | –27,3%    |
| <b>6 – Obesity Type III</b>    | 324                   | 323                     | –0,3%     |

Untuk mengatasi imbalance pada data hasil split latih (bukan pada seluruh dataset, guna menghindari kebocoran informasi

| Kelas | Sebelum (Train) | Setelah Undersampling | Setelah SMOTE (Oversampling) |
|-------|-----------------|-----------------------|------------------------------|
| 0     | 218             | 218                   | 281                          |
| 1     | 229             | 218                   | 281                          |
| 2     | 232             | 218                   | 281                          |
| 3     | 223             | 218                   | 281                          |
| 4     | 281             | 218                   | 281                          |
| 5     | 237             | 218                   | 281                          |
| 6     | 259             | 218                   | 281                          |

#### 4.5 Normalisasi (Scaling)

Dua teknik scaling dibandingkan secara eksploratif — **Min-Max Scaler** dan **Robust Scaler** — dengan memvisualisasikan histogram sebelum dan sesudah transformasi untuk seluruh fitur numerik. **Min-Max Scaler** dipilih sebagai scaler final untuk pelatihan model, dengan pertimbangan:

- Sebagian besar fitur pada dataset ini (FCVC, NCP, CH2O, FAF, TUE) sudah berskala ordinal sempit (0–3 atau 1–4), sehingga Min-Max Scaling ke rentang [0,1] menjaga proporsi relatif antar nilai secara intuitif.
- KNN dan SVM — dua dari tiga algoritma wajib pada project ini — sangat sensitif terhadap skala fitur karena keduanya bergantung pada perhitungan jarak/margin, sehingga scaling menjadi langkah wajib, bukan opsional.
- Robust Scaler (berbasis median dan IQR) lebih cocok untuk data dengan outlier ekstrem, namun karena outlier sudah ditangani terpisah pada Subbab 4.3, Min-Max Scaler dinilai cukup dan lebih mudah diinterpretasikan.

#### 4.6 Pemeriksaan Potensi Data Leakage

Tiga praktik eksplisit diterapkan pada notebook untuk mencegah kebocoran informasi dari data uji ke proses pelatihan:

- Scaler di-fit hanya pada data latih.** Kode `scaler.fit_transform(X_train)` diikuti `scaler.transform(X_test)` — bukan `fit_transform()` pada `X_test` — memastikan statistik penskalaan (min/max) tidak "mengintip" distribusi data uji.
- Balancing data (undersampling/SMOTE) hanya diterapkan pada partisi latih,** setelah `train_test_split` dilakukan. Data uji tetap merepresentasikan distribusi kelas asli yang tidak diubah, sehingga

evaluasi model mencerminkan kondisi dunia nyata yang tidak diketahui proporsinya sebelumnya.

- c) **Split data dilakukan dengan stratify=y**, menjaga proporsi tiap kelas pada partisi latih dan uji tetap representatif terhadap dataset asli, sehingga metrik evaluasi tidak bias akibat pembagian data yang kebetulan timpang.

Tidak ditemukan indikasi *leakage* langsung seperti fitur turunan dari target (misalnya kolom BMI yang dihitung dari Height/Weight kemudian dijadikan fitur terpisah) — seluruh 16 fitur prediktor bersifat independen terhadap label NObedesdad.

## BAB V DESAIN EKSPERIMEN

### 5.1 Strategi Pembagian Data (Train-Test Split)

Seluruh eksperimen pada project ini menggunakan skema **holdout split 80:20** (train\_test\_split dengan test\_size=0.2, random\_state=42), dengan parameter **stratify=y** untuk menjaga proporsi ketujuh kelas target tetap representatif pada partisi latih maupun uji. Pembagian ini dilakukan **setelah** proses encoding namun **sebelum** proses scaling dan resampling, sejalan dengan praktik pencegahan data leakage.

Pada skenario data hasil cleaning (1.388 baris), pembagian 80:20 menghasilkan **1.110 baris data latih** dan **278 baris data uji**. Data uji ini tidak pernah disentuh oleh proses balancing (undersampling/SMOTE) maupun proses fit scaler, sehingga metrik evaluasi pada Bab VI benar-benar mencerminkan performa model pada data yang belum pernah dilihat sebelumnya (*unseen data*).

### 5.2 Algoritma Baseline vs Algoritma yang Dioptimasi

Untuk setiap algoritma, project ini membedakan dua tahap pengujian:

- a) **Model baseline** algoritma dilatih menggunakan **hyperparameter default** dari scikit-learn (mis. KNeighborsClassifier(), SVC(), GaussianNB(), DecisionTreeClassifier(), RandomForestClassifier()) tanpa parameter khusus). Baseline ini dijalankan pada notebook (Notebook/uas\_ml\_obesity\_prediction.ipynb, Bagian 3) untuk setiap kombinasi model x skenario data, dan menjadi titik acuan untuk mengukur seberapa besar kontribusi optimasi hyperparameter terhadap performa akhir.
- b) **Model optimasi** hyperparameter disesuaikan secara manual berdasarkan hasil eksplorasi berulang (*iterative manual tuning*) pada data hasil cleaning, dengan prinsip yang sama dengan Grid Search pada paper acuan (Bab II): mencoba beberapa kombinasi nilai parameter yang relevan dengan karakteristik masing-masing algoritma, lalu memilih kombinasi dengan akurasi validasi terbaik. Konfigurasi hasil tuning inilah yang digunakan pada seluruh evaluasi akhir di Src/ml\_core.py (fungsi build\_models()) dan dilaporkan pada Bab VI.

Algoritma **KNN, Naive Bayes, dan SVM** merupakan tiga algoritma wajib sesuai lembar soal UAS. Sebagai pembanding tambahan sekaligus bahan diskusi trade-off pada Bab VII, project ini juga menyertakan **Decision Tree** dan **Random Forest**, sehingga total terdapat **5 algoritma** yang diuji pada setiap skenario data.

### 5.3 Metrik Evaluasi Utama

Empat metrik utama digunakan secara konsisten di seluruh tahap eksperimen, baik pada baseline, tuning, maupun validasi akhir:

- a) **Accuracy**: proporsi prediksi benar terhadap keseluruhan data uji; mudah diinterpretasikan namun berpotensi menyesatkan pada dataset dengan kelas tidak seimbang, sehingga tidak dijadikan satu-satunya acuan pengambilan keputusan.
- b) **Precision (macro-average)**: rata-rata precision dihitung secara setara untuk ketujuh kelas tanpa mempertimbangkan jumlah sampel tiap kelas (`average='macro', zero_division=0`).
- c) **Recall (macro-average)**: rata-rata recall dengan bobot setara antar kelas, penting untuk memastikan model tidak mengabaikan kelas minoritas seperti Insufficient Weight.
- d) **F1-Score (macro-average)**: harmonic mean dari precision dan recall macro; dijadikan metrik keputusan utama (primary metric) dalam pemilihan model terbaik, karena secara eksplisit menyeimbangkan false positive dan false negative pada seluruh kelas secara setara.

## BAB VI

### HASIL EKSPERIMEN BASELINE DAN OPTIMASI

#### 6.1 Hasil Baseline vs Optimized

Setiap algoritma dievaluasi pada dua basis data (Data Asli dan Data Cleaning) dan tiga skema balancing (Original, Undersampling, SMOTE), masing-masing sebelum (baseline) dan sesudah (optimized) hyperparameter tuning via GridSearchCV, dituning terpisah untuk setiap kombinasi basis data x skema balancing.

##### a) Data Original

- KNN

|   | Dataset       | Model     | Accuracy | Precision | Recall   | Macro F1 | Balanced Accuracy |
|---|---------------|-----------|----------|-----------|----------|----------|-------------------|
| 0 | Original      | Baseline  | 0.789598 | 0.783741  | 0.786224 | 0.780381 | 0.786224          |
| 1 | Original      | Optimized | 0.817967 | 0.811380  | 0.814836 | 0.809025 | 0.814836          |
| 2 | Undersampling | Baseline  | 0.761229 | 0.756391  | 0.759201 | 0.750881 | 0.759201          |
| 3 | Undersampling | Optimized | 0.808511 | 0.803134  | 0.805406 | 0.799536 | 0.805406          |
| 4 | SMOTE         | Baseline  | 0.789598 | 0.782045  | 0.786306 | 0.780568 | 0.786306          |
| 5 | SMOTE         | Optimized | 0.817967 | 0.813581  | 0.815358 | 0.808208 | 0.815358          |

- Decision Tree

|   | Dataset       | Model     | Accuracy | Precision | Recall   | Macro F1 | Balanced Accuracy |
|---|---------------|-----------|----------|-----------|----------|----------|-------------------|
| 0 | Original      | Baseline  | 0.926714 | 0.928255  | 0.922798 | 0.924643 | 0.922798          |
| 1 | Original      | Optimized | 0.919622 | 0.921331  | 0.915408 | 0.917073 | 0.915408          |
| 2 | Undersampling | Baseline  | 0.917258 | 0.916708  | 0.913972 | 0.914647 | 0.913972          |
| 3 | Undersampling | Optimized | 0.910165 | 0.908339  | 0.907005 | 0.907386 | 0.907005          |
| 4 | SMOTE         | Baseline  | 0.914894 | 0.916039  | 0.910987 | 0.912761 | 0.910987          |
| 5 | SMOTE         | Optimized | 0.914894 | 0.916039  | 0.910987 | 0.912761 | 0.910987          |

- Naïve Bayes

|   | Dataset       | Model     | Accuracy | Precision | Recall   | Macro F1 | Balanced Accuracy |
|---|---------------|-----------|----------|-----------|----------|----------|-------------------|
| 0 | Original      | Baseline  | 0.612293 | 0.654025  | 0.609499 | 0.595211 | 0.609499          |
| 1 | Original      | Optimized | 0.612293 | 0.654025  | 0.609499 | 0.595211 | 0.609499          |
| 2 | Undersampling | Baseline  | 0.612293 | 0.644617  | 0.609341 | 0.593653 | 0.609341          |
| 3 | Undersampling | Optimized | 0.612293 | 0.644617  | 0.609341 | 0.593653 | 0.609341          |
| 4 | SMOTE         | Baseline  | 0.614657 | 0.657012  | 0.612220 | 0.593318 | 0.612220          |
| 5 | SMOTE         | Optimized | 0.614657 | 0.657012  | 0.612220 | 0.593318 | 0.612220          |

- Random Forest



|   | Dataset       | Model     | Accuracy | Precision | Recall   | Macro F1 | Balanced Accuracy |
|---|---------------|-----------|----------|-----------|----------|----------|-------------------|
| 0 | Original      | Baseline  | 0.947991 | 0.952842  | 0.945935 | 0.947345 | 0.945935          |
| 1 | Original      | Optimized | 0.947991 | 0.953330  | 0.945935 | 0.947199 | 0.945935          |
| 2 | Undersampling | Baseline  | 0.943262 | 0.947905  | 0.942036 | 0.942657 | 0.942036          |
| 3 | Undersampling | Optimized | 0.936170 | 0.941126  | 0.934464 | 0.935332 | 0.934464          |
| 4 | SMOTE         | Baseline  | 0.943262 | 0.947698  | 0.941009 | 0.942579 | 0.941009          |
| 5 | SMOTE         | Optimized | 0.943262 | 0.946479  | 0.941191 | 0.942044 | 0.941191          |

- SVM

|   | Dataset       | Model     | Accuracy | Precision | Recall   | Macro F1 | Balanced Accuracy |
|---|---------------|-----------|----------|-----------|----------|----------|-------------------|
| 0 | Original      | Baseline  | 0.820331 | 0.816262  | 0.818344 | 0.816508 | 0.818344          |
| 1 | Original      | Optimized | 0.950355 | 0.950455  | 0.949311 | 0.949297 | 0.949311          |
| 2 | Undersampling | Baseline  | 0.810875 | 0.807113  | 0.809758 | 0.807153 | 0.809758          |
| 3 | Undersampling | Optimized | 0.952719 | 0.952024  | 0.951774 | 0.951274 | 0.951774          |
| 4 | SMOTE         | Baseline  | 0.822695 | 0.820064  | 0.821652 | 0.819762 | 0.821652          |
| 5 | SMOTE         | Optimized | 0.955083 | 0.955933  | 0.954237 | 0.954441 | 0.954237          |

## b) Data Clean

- KNN

|   | Dataset       | Model     | Accuracy | Precision | Recall   | Macro F1 | Balanced Accuracy |
|---|---------------|-----------|----------|-----------|----------|----------|-------------------|
| 0 | Cleaning      | Baseline  | 0.762590 | 0.727303  | 0.731659 | 0.724529 | 0.731659          |
| 1 | Cleaning      | Optimized | 0.794964 | 0.771170  | 0.773516 | 0.767259 | 0.773516          |
| 2 | Undersampling | Baseline  | 0.758993 | 0.717750  | 0.730952 | 0.716428 | 0.730952          |
| 3 | Undersampling | Optimized | 0.794964 | 0.754915  | 0.775033 | 0.757345 | 0.775033          |
| 4 | SMOTE         | Baseline  | 0.791367 | 0.764774  | 0.764777 | 0.760492 | 0.764777          |
| 5 | SMOTE         | Optimized | 0.798561 | 0.770651  | 0.776839 | 0.768654 | 0.776839          |

- Decision Tree

|   | Dataset       | Model     | Accuracy | Precision | Recall   | Macro F1 | Balanced Accuracy |
|---|---------------|-----------|----------|-----------|----------|----------|-------------------|
| 0 | Cleaning      | Baseline  | 0.924460 | 0.911512  | 0.912528 | 0.911532 | 0.912528          |
| 1 | Cleaning      | Optimized | 0.917266 | 0.904873  | 0.902324 | 0.903183 | 0.902324          |
| 2 | Undersampling | Baseline  | 0.935252 | 0.924159  | 0.924616 | 0.924127 | 0.924616          |
| 3 | Undersampling | Optimized | 0.938849 | 0.928428  | 0.928818 | 0.928263 | 0.928818          |
| 4 | SMOTE         | Baseline  | 0.956835 | 0.949963  | 0.950231 | 0.949873 | 0.950231          |
| 5 | SMOTE         | Optimized | 0.956835 | 0.949963  | 0.950231 | 0.949873 | 0.950231          |

- Naïve Bayes

|   | Dataset       | Model     | Accuracy | Precision | Recall   | Macro F1 | Balanced Accuracy |
|---|---------------|-----------|----------|-----------|----------|----------|-------------------|
| 0 | Cleaning      | Baseline  | 0.571942 | 0.467723  | 0.498064 | 0.407310 | 0.498064          |
| 1 | Cleaning      | Optimized | 0.672662 | 0.710706  | 0.614671 | 0.595452 | 0.614671          |
| 2 | Undersampling | Baseline  | 0.579137 | 0.553353  | 0.492544 | 0.458231 | 0.492544          |
| 3 | Undersampling | Optimized | 0.651079 | 0.700167  | 0.579869 | 0.576827 | 0.579869          |
| 4 | SMOTE         | Baseline  | 0.600719 | 0.763461  | 0.534060 | 0.464047 | 0.534060          |
| 5 | SMOTE         | Optimized | 0.708633 | 0.725982  | 0.655817 | 0.645633 | 0.655817          |

- Random Forest

|   | Dataset       | Model     | Accuracy | Precision | Recall   | Macro F1 | Balanced Accuracy |
|---|---------------|-----------|----------|-----------|----------|----------|-------------------|
| 0 | Cleaning      | Baseline  | 0.949640 | 0.947039  | 0.937092 | 0.940285 | 0.937092          |
| 1 | Cleaning      | Optimized | 0.949640 | 0.949155  | 0.935653 | 0.940099 | 0.935653          |
| 2 | Undersampling | Baseline  | 0.938849 | 0.931606  | 0.926641 | 0.928304 | 0.926641          |
| 3 | Undersampling | Optimized | 0.946043 | 0.940201  | 0.935605 | 0.937327 | 0.935605          |
| 4 | SMOTE         | Baseline  | 0.956835 | 0.959529  | 0.944956 | 0.949478 | 0.944956          |
| 5 | SMOTE         | Optimized | 0.956835 | 0.959529  | 0.944956 | 0.949478 | 0.944956          |

- SVM

|   | Dataset       | Model     | Accuracy | Precision | Recall   | Macro F1 | Balanced Accuracy |
|---|---------------|-----------|----------|-----------|----------|----------|-------------------|
| 0 | Cleaning      | Baseline  | 0.827338 | 0.803625  | 0.798550 | 0.800474 | 0.798550          |
| 1 | Cleaning      | Optimized | 0.964029 | 0.957051  | 0.960974 | 0.957957 | 0.960974          |
| 2 | Undersampling | Baseline  | 0.791367 | 0.759058  | 0.761403 | 0.759232 | 0.761403          |
| 3 | Undersampling | Optimized | 0.935252 | 0.922959  | 0.925879 | 0.923385 | 0.925879          |
| 4 | SMOTE         | Baseline  | 0.841727 | 0.820234  | 0.815718 | 0.817329 | 0.815718          |
| 5 | SMOTE         | Optimized | 0.935252 | 0.921394  | 0.924417 | 0.922282 | 0.924417          |

## 6.2 Error Analysis

Berdasarkan cell error analysis pada notebook:

- Dari 278 data uji, SVM meleset pada **10 sampel (3,6%)** — seluruhnya antar kelas bertetangga langsung, tidak ada kesalahan yang melompat dua tingkat atau lebih (mis. tidak pernah memprediksi Obesity Type III padahal aslinya Normal Weight).
- Pola dominan: Normal Weight tertukar Overweight Level I/Insufficient Weight, serta Overweight Level I–II saling tertukar. Saat BMI dihitung ulang dari Height/Weight pada sampel yang salah, nilainya berkisar **24,2–24,8** — tepat di sekitar ambang WHO BMI 25.
- Permutation importance** (bukan `feature_importances_`, karena tidak berlaku untuk SVM): Weight paling dominan (penurunan F1-macro

0,728 saat diacak), diikuti Height (0,322), Gender (0,139), Age (0,057). Fitur gaya hidup (merokok, konsumsi alkohol, moda transportasi) nyaris tidak berkontribusi.

- d) **Kesimpulan:** kesalahan mencerminkan ambiguitas inheren data di sekitar garis batas BMI — bukan kelemahan model. SVM sudah menangkap batas keputusan yang sejalan dengan definisi klinis BMI, hanya kurang presisi tepat di titik ambang, yang secara alami sulit dibedakan bahkan oleh manusia.

## **BAB VII PEMBAHASAN**

### **7.1 Model Terbaik**

Berdasarkan seluruh hasil eksperimen, **Support Vector Machine (SVM)** merupakan model dengan performa terbaik dibandingkan K-Nearest Neighbors (KNN), Naïve Bayes, Decision Tree, dan Random Forest. Pada skenario **data cleaning dengan hyperparameter tuning**, SVM memperoleh **Accuracy 96,40%**, **Precision 95,71%**, **Recall Macro 96,10%**, **F1-Score Macro 95,80%**, dan **Balanced Accuracy 96,10%**. Nilai tersebut menunjukkan bahwa SVM mampu mengklasifikasikan tujuh kategori tingkat obesitas dengan tingkat ketepatan yang tinggi.

Jika dibandingkan dengan algoritma lain, KNN mengalami peningkatan performa setelah tuning namun masih berada di bawah SVM. Naïve Bayes menghasilkan performa paling rendah karena asumsi independensi antar fitur kurang sesuai dengan karakteristik dataset. Decision Tree dan Random Forest memiliki akurasi yang tinggi, tetapi masih sedikit di bawah SVM sehingga model SVM dipilih sebagai model utama pada aplikasi prediksi tingkat obesitas.

### **7.2 Alasan Akademik**

Performa SVM yang lebih baik dipengaruhi oleh kemampuannya membentuk **hyperplane** yang optimal untuk memisahkan kelas-kelas pada dataset. Karakteristik dataset obesitas yang memiliki hubungan nonlinier antar atribut, seperti berat badan, tinggi badan, usia, serta kebiasaan hidup, dapat dipelajari dengan baik oleh SVM setelah dilakukan proses preprocessing dan hyperparameter tuning.

Selain itu, tahapan preprocessing berupa pembersihan data, encoding, normalisasi menggunakan Min-Max Scaler, serta penanganan ketidakseimbangan kelas membantu meningkatkan kualitas data sebelum proses pelatihan model. Hasil ini menunjukkan bahwa kombinasi preprocessing yang baik dan proses optimasi parameter memberikan pengaruh yang signifikan terhadap peningkatan performa model klasifikasi.

### 7.3 Implikasi bagi Institusi

Model prediksi tingkat obesitas yang dikembangkan dapat dimanfaatkan sebagai alat bantu skrining awal bagi institusi pendidikan maupun fasilitas kesehatan. Aplikasi yang dibangun mampu memberikan prediksi tingkat obesitas berdasarkan data gaya hidup pengguna sehingga dapat membantu meningkatkan kesadaran masyarakat terhadap pentingnya menjaga pola hidup sehat.

Meskipun demikian, hasil prediksi yang diberikan bukan merupakan diagnosis medis dan tidak dapat menggantikan pemeriksaan oleh tenaga kesehatan profesional. Oleh karena itu, aplikasi ini lebih tepat digunakan sebagai **decision support system** yang mendukung pengambilan keputusan awal serta memenuhi prinsip **Outcome Based Education (OBE)** melalui penerapan machine learning dalam penyelesaian permasalahan nyata.

## **BAB VII**

### **DESAIN APLIKASI**

#### **8.1 Arsitektur Backend**

Aplikasi prediksi tingkat obesitas dikembangkan menggunakan bahasa pemrograman **Python** dengan framework **Streamlit** sebagai antarmuka utama dan **FastAPI** sebagai penyedia layanan API. Model machine learning terbaik hasil proses pelatihan disimpan dalam folder **Models** menggunakan format **Joblib**, sehingga model dapat digunakan kembali tanpa melakukan proses training setiap kali aplikasi dijalankan. Seluruh proses preprocessing, pemanggilan model, hingga proses prediksi dikelola oleh modul pada folder **Src** agar setiap komponen memiliki fungsi yang terpisah dan mudah dikembangkan.

Alur kerja sistem dimulai dari pengguna yang memasukkan data melalui antarmuka Streamlit. Data tersebut kemudian diproses menggunakan tahapan preprocessing yang sama seperti saat pelatihan model, meliputi encoding dan normalisasi menggunakan **Min-Max Scaler**. Selanjutnya data diproses oleh model SVM untuk menghasilkan prediksi tingkat obesitas, kemudian hasil prediksi beserta informasi pendukung ditampilkan kembali kepada pengguna.


#### **8.2 Alur UI/UX Aplikasi**

Antarmuka aplikasi dirancang sederhana, responsif, dan mudah digunakan oleh pengguna tanpa memerlukan pengetahuan mengenai machine learning. Aplikasi terdiri dari empat menu utama yaitu **Dashboard Data**, **Prediktor Tingkat Obesitas**, **Perbandingan Eksperimen**, dan **Interpretasi Model**. Setiap menu dirancang untuk menampilkan informasi secara bertahap sehingga pengguna dapat memahami dataset, melakukan prediksi, membandingkan performa model, serta melihat interpretasi hasil prediksi.

Pada menu **Dashboard Data** ditampilkan informasi mengenai dataset dan distribusi data. Menu **Prediktor Tingkat Obesitas** digunakan untuk memasukkan data pengguna dan memperoleh hasil prediksi. Menu **Perbandingan Eksperimen** menampilkan hasil evaluasi seluruh algoritma pada berbagai skenario pengujian, sedangkan menu **Interpretasi Model** menampilkan analisis fitur yang paling berpengaruh terhadap hasil prediksi.

## 8.3 Screenshot Aplikasi

### a) Menu Dashboard



### b) Menu Prediktor Obesitas


The screenshot shows the 'Prediksi Risiko & Tingkat Obesitas' interface. The sidebar is identical to the dashboard. The main content area has a title 'Prediksi Risiko & Tingkat Obesitas' and a subtitle 'Masukkan profil fisik dan gaya hidup pasien untuk memprediksi tingkat obesitas beserta probabilitas kemunculannya secara etis.' Below this is a form with three sections: '1. Informasi Dasar', '2. Kebiasaan Makan & Pola Diet', and '3. Aktivitas Fisik & Kebiasaan Lainnya'. Each section contains various input fields and sliders for user data. At the bottom is a 'Prediksi Tingkat Obesitas' button.

| Jenis Kelamin | Usla (tahun) | Tinggi Badan (m) | Berat Badan (kg) |
|---------------|--------------|------------------|------------------|
| Laki-laki     | 24           | 1.70             | 70               |


| Riwayat Obesitas Keluarga? | Konsumsi Makanan Tinggi Kalori (FAVC)? | Konsumsi Sayur (FVCV) (1=Jarang, 2=Kadang, 3=Sering) | Jumlah Makan Utama/Hari (NCP) |
|----------------------------|----------------------------------------|------------------------------------------------------|-------------------------------|
| Ya                         | Ya                                     | 2                                                    | 3                             |

| Ngemil di Sela Jam Makan (CAEC) | Minum Air Putih/Hari (CH2O) (1-3 Liter) | Memonitor Asupan Kalori (SCC)? | Kebiasaan Merokok (SMOKE)? |
|---------------------------------|-----------------------------------------|--------------------------------|----------------------------|
| Tidak                           | 2                                       | Ya                             | Ya                         |

| Aktivitas Fisik/Minggu (FAF) (0=Tidak Pernah, 1=Jarang, 2=Kadang, 3=Sering) | Waktu Layar Gadget/Hari (TUE) (0-2 Jam) | Frekuensi Minum Alkohol (CALC) | Transportasi Utama (MTRANS) |
|-----------------------------------------------------------------------------|-----------------------------------------|--------------------------------|-----------------------------|
| 1                                                                           | 1                                       | Tidak                          | Berjalan Kaki               |




### c) Menu Perbandingan Eksperimen





#### d) Menu Interpretasi Model



### 8.4 Cara Menjalankan Program

Project dapat dijalankan dengan menginstal seluruh dependensi yang terdapat pada file **requirements.txt**. Setelah proses instalasi selesai, pengguna dapat menjalankan aplikasi Streamlit menggunakan file `app_streamlit.py` atau menjalankan layanan API menggunakan `api_fastapi.py`. Selain itu, project juga telah menyediakan **Dockerfile** dan **docker-compose.yml** sehingga aplikasi dapat dijalankan menggunakan Docker tanpa melakukan instalasi dependensi secara manual.

Untuk menjalankan aplikasi secara lokal, pengguna dapat menggunakan perintah berikut.

```
pip install -r requirements.txt
streamlit run app_streamlit.py
```

Apabila menggunakan Docker, aplikasi dapat dijalankan menggunakan perintah berikut.

```
docker compose up --build
```

Setelah aplikasi berhasil dijalankan, pengguna dapat mengakses dashboard melalui browser, memasukkan data yang diperlukan, kemudian melihat hasil prediksi tingkat obesitas beserta informasi evaluasi model yang tersedia pada setiap menu aplikasi.

## **BAB IX**

### **KESIMPULAN DAN REKOMENDASI**

#### **10.1 Kesimpulan (Capaian Outcome)**

Penelitian ini berhasil membangun sistem klasifikasi tingkat obesitas menggunakan pendekatan Machine Learning dengan membandingkan lima algoritma klasifikasi, yaitu K-Nearest Neighbors (KNN), Naive Bayes, Support Vector Machine (SVM), Decision Tree, dan Random Forest pada enam skenario pengolahan data. Tahapan penelitian meliputi data preprocessing, data cleaning, penanganan ketidakseimbangan data menggunakan undersampling dan oversampling, pelatihan model, evaluasi performa, interpretasi model menggunakan Explainable Artificial Intelligence (XAI), serta implementasi aplikasi berbasis Streamlit.

Berdasarkan hasil pengujian, algoritma **Support Vector Machine (SVM)** pada skenario **Data Cleaning** memberikan performa terbaik dengan nilai:

Accuracy : **96,40%**

Precision : **95,80%**

Recall : **95,80%**

F1-Score : **95,80%**

Balanced Accuracy : **95,80%**

Hasil tersebut menunjukkan bahwa proses pembersihan data mampu meningkatkan kualitas model secara signifikan dibandingkan penggunaan data mentah maupun skenario penanganan ketidakseimbangan lainnya.

Selain menghasilkan model dengan performa tinggi, penelitian ini juga berhasil mengimplementasikan model ke dalam aplikasi berbasis **Streamlit** yang menyediakan beberapa fitur utama, yaitu:

- a) Dashboard analisis dataset obesitas.
- b) Prediksi tingkat obesitas berdasarkan data pengguna.
- c) Perbandingan performa seluruh eksperimen.
- d) Interpretasi model menggunakan Permutation Feature Importance dan Learning Curve.

Melalui Permutation Feature Importance diperoleh bahwa fitur **Weight, Height, Gender, Age**, dan **FCVC** merupakan variabel yang paling berpengaruh terhadap keputusan model. Dengan demikian, penelitian ini telah memenuhi tujuan utama, yaitu menghasilkan sistem klasifikasi obesitas yang memiliki performa tinggi, mudah digunakan, serta mampu memberikan interpretasi terhadap hasil prediksi.

## **10.2 Keterbatasan Penelitian**

Meskipun memperoleh hasil yang baik, penelitian ini masih memiliki beberapa keterbatasan, antara lain:

- a) Dataset yang digunakan berasal dari dataset publik sehingga karakteristik data belum tentu sepenuhnya merepresentasikan kondisi masyarakat Indonesia.
- b) Aplikasi Streamlit masih bersifat prototipe sehingga belum memiliki fitur autentikasi pengguna, penyimpanan riwayat prediksi, maupun integrasi dengan basis data.
- c) Penelitian hanya membandingkan lima algoritma machine learning sehingga masih terdapat peluang untuk mengevaluasi algoritma lain yang lebih modern.

## **10.3 Rekomendasi Pengembangan**

Beberapa rekomendasi yang dapat dilakukan pada penelitian selanjutnya adalah sebagai berikut.

- a) Menggunakan dataset yang lebih besar, lebih beragam, serta berasal dari institusi kesehatan agar model memiliki kemampuan generalisasi yang lebih baik.
- b) Menambahkan algoritma machine learning modern seperti XGBoost, LightGBM, CatBoost, maupun Deep Learning sebagai pembanding.
- c) Mengembangkan aplikasi menjadi sistem berbasis web yang terhubung dengan database sehingga data prediksi dapat disimpan dan dianalisis kembali.
- d) Melakukan deployment aplikasi pada layanan cloud agar dapat diakses oleh pengguna secara daring tanpa memerlukan instalasi lokal.

## **BAB X**

### **LAMPIRAN**

#### **10.1 Struktur Project**

Struktur direktori proyek yang dikembangkan pada penelitian ini adalah sebagai berikut.

uas-ml-obesity-A11.2024.15547-A11.4410-Tegar Scaesario/

- ├── Data/
  - ├── ObesityDataSet\_raw\_and\_data\_sinthetic.csv
  - ├── data\_dictionary.md
  - └── source\_dataset.md
- ├── Models/
  - ├── model\_terbaik.joblib
  - └── scaler\_minmax.joblib
- ├── Notebook/
  - └── uas\_ml\_obesity\_prediction.ipynb
- ├── Presentation/
  - └── presentasi\_uas\_ml.pdf
- ├── Report/
  - └── laporan\_uas\_ml\_obesity.pdf
- ├── Reports/
  - ├── all\_experiment\_results.csv
  - ├── audit\_dataset.json
  - └── classification\_reports.json
- ├── Src/
  - ├── data\_generator.py
  - ├── ml\_core.py
  - ├── train.py
  - └── predict.py
- ├── app\_streamlit.py
- ├── api\_fastapi.py
- ├── Dockerfile
- ├── docker-compose.yml
- └── requirements.txt

- └─ readme.md
- └─ Lembar Jawab-15547.pdf
- └─ Paper.pdf

## 10.2 Penjelasan File Penting

| File                                     | Fungsi                                                                                                                                                                                                  |
|------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Notebook/uas_ml_obesity_prediction.ipynb | Notebook utama yang berisi proses eksplorasi data, preprocessing, pelatihan model, evaluasi, visualisasi hasil, serta interpretasi model menggunakan Permutation Feature Importance dan Learning Curve. |
| Src/data_generator.py                    | Mengelola proses persiapan dataset, termasuk pembagian data dan pembuatan variasi dataset untuk berbagai skenario eksperimen seperti data asli, data cleaning, undersampling, dan oversampling.         |
| Src/ml_core.py                           | Berisi fungsi-fungsi inti machine learning, meliputi preprocessing, pelatihan model, evaluasi performa, serta utilitas yang digunakan oleh program utama.                                               |
| Src/train.py                             | Menjalankan proses pelatihan lima algoritma machine learning pada seluruh skenario eksperimen, kemudian menyimpan model dan hasil evaluasi ke dalam folder Reports dan Models.                          |
| Src/predict.py                           | Memuat model terbaik dan melakukan prediksi tingkat obesitas berdasarkan data masukan pengguna.                                                                                                         |
| app.py                                   | Aplikasi berbasis Streamlit yang menyediakan antarmuka pengguna untuk melakukan prediksi, melihat dashboard analisis data, membandingkan performa model, dan menampilkan interpretasi model.            |
| Models/                                  | Menyimpan model machine learning terbaik beserta file scaler                                                                                                                                            |

|                    |                                                                                                                                                      |
|--------------------|------------------------------------------------------------------------------------------------------------------------------------------------------|
|                    | yang digunakan pada proses prediksi.                                                                                                                 |
| Data/              | Berisi dataset asli serta dataset hasil preprocessing yang digunakan selama proses pelatihan dan pengujian model.                                    |
| Reports/           | Berisi hasil evaluasi model, laporan klasifikasi, confusion matrix, learning curve, feature importance, audit dataset, dan hasil eksperimen lainnya. |
| requirements.txt   | Daftar pustaka (library) Python yang diperlukan untuk menjalankan aplikasi dan proses machine learning.                                              |
| Dockerfile         | Konfigurasi untuk membangun image Docker sehingga aplikasi dapat dijalankan dalam lingkungan yang konsisten.                                         |
| docker-compose.yml | Konfigurasi untuk menjalankan aplikasi beserta layanan pendukung menggunakan Docker Compose.                                                         |
| README.md          | Dokumentasi proyek yang menjelaskan tujuan penelitian, struktur direktori, cara instalasi, dan langkah menjalankan aplikasi.                         |

### 10.3 Dokumentasi Demo Aplikasi

Link Video:

[https://drive.google.com/drive/folders/1mQ3qgV8gsEzcwnxQ2hwm05ehSzXwQGpb?usp=drive\\_link](https://drive.google.com/drive/folders/1mQ3qgV8gsEzcwnxQ2hwm05ehSzXwQGpb?usp=drive_link)

### 10.4 Repository Projek

Link Repository github:

<https://github.com/tegarscaesario/obesityprediction>