

**LAPORAN AKADEMIK UAS
PEMBELAJARAN MESIN A11.4410**



Dosen Pengampu:

Junta Zeniarja, M.Kom

Disusun Oleh:

Tegar Scasario (A11.2024.15547)

**PROGRAM STUDI SARJANA TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS DIAN NUSWANTORO
2026**

BAB I

PENDAHULUAN

1.1 Latar Belakang

Obesitas merupakan salah satu tantangan kesehatan masyarakat paling serius pada abad ini. Sejak tahun 1975, angka obesitas global meningkat hampir tiga kali lipat, dengan lebih dari 1,9 miliar orang kelebihan berat badan dan sekitar 650 juta di antaranya mengalami obesitas (Salliah Shafi et al., 2026). Obesitas berkontribusi terhadap penyakit kardiovaskular, hipertensi, diabetes tipe 2, gangguan sendi, hingga gangguan psikologis, dengan penyebab yang bersifat multifaktorial (genetik, pola makan, aktivitas fisik, sosial-ekonomi, dan gaya hidup).

Pendekatan konvensional seperti Body Mass Index (BMI) bersifat linier dan tidak mampu menangkap interaksi non-linear antar variabel gaya hidup. Pendekatan machine learning — KNN, Naive Bayes, dan SVM — memungkinkan sistem mempelajari pola dari data kebiasaan hidup untuk memprediksi tingkat obesitas secara lebih akurat. Project ini membangun sistem klasifikasi tingkat obesitas dan membungkusnya dalam dashboard interaktif berbasis Streamlit agar dapat diakses pengguna non-teknis.

1.2 Tujuan Project

- Membangun model klasifikasi ML untuk memprediksi tingkat obesitas (Insufficient Weight–Obesity Type III) berdasarkan atribut demografis, kebiasaan makan, dan gaya hidup.
- Membandingkan performa KNN, Naive Bayes, dan SVM pada beberapa skenario penanganan data (data asli, undersampling, SMOTE) untuk menentukan model terbaik.
- Melakukan audit dan preprocessing data secara sistematis: missing value, duplikasi, outlier, encoding, scaling, serta pemeriksaan data leakage dan class imbalance.
- Mengimplementasikan hasil model ke dalam dashboard interaktif yang menampilkan hasil prediksi dan interpretasi model (feature importance).
- Menyusun laporan akademik yang mendokumentasikan keseluruhan proses penelitian.

BAB II

STUDI LITERATUR

2.1 Mini-Review Paper Acuan

Komponen	Uraian
Penulis	Salliah Shafi, Gufran Ahmad Ansari, Lamees Alhazaa
Tahun / Jurnal	2026, Systems and Soft Computing (Elsevier), Vol. 8, Art. 200472
Judul	Optimizing machine learning models for obesity risk prediction through hyperparameter tuning
Dataset	UCI Obesity Levels Dataset (2.111 baris, 17 atribut)
Metode	Logistic Regression, SVM, KNN, Decision Tree; tuning via Grid/Random Search; feature engineering Cuckoo Search; interpretasi SHAP
Hasil Utama	Logistic Regression tertinggi (99,63%), KNN (94,33%), SVM (89,60%), Decision Tree (79,68%). Fitur terpenting: berat badan, tinggi badan, jenis kelamin
Relevansi	Dataset sama; digunakan sebagai acuan tuning, cross-validation, feature selection, dan explainability

2.2 Strategi Optimasi yang Diadaptasi

- Hyperparameter tuning via GridSearchCV pada KNN, Naive Bayes, dan SVM.
- Stratified k-fold cross-validation agar proporsi tiap kelas terjaga di setiap fold.
- Feature selection sederhana berbasis korelasi dan mutual information (pengganti Cuckoo Search).
- Penanganan class imbalance dengan undersampling dan SMOTE (oversampling).
- Interpretasi model menggunakan Permutation Feature Importance dan error analysis, sebagai pengganti SHAP.

BAB III

DATASET DAN DATA DICTIONARY

3.1 Sumber Data

Dataset yang digunakan adalah Obesity Levels Dataset dari UCI Machine Learning Repository (ObesityDataSet_raw_and_data_synthetic.csv), yang juga menjadi rujukan pada paper utama (Shafi et al., 2026). Dataset terdiri atas 2.111 baris dan 17 atribut (16 fitur + 1 target), berasal dari survei individu di Meksiko, Peru, dan Kolombia, dikombinasikan dengan data sintetis hasil SMOTE oleh penyusun dataset asli.

Sumber: archive.ics.uci.edu/dataset/544/estimation+of+obesity+levels+based+on+eating+habits+and+physical+condition

3.2 Ringkasan Atribut

Atribut	Tipe	Deskripsi Singkat
Gender, Age	Kategorik/Numerik	Jenis kelamin dan usia (14–61 th)
Height, Weight	Numerik	Tinggi (1,45–1,98 m) dan berat (39–173 kg)
family_history, FAVC, SMOKE, SCC	Biner	Riwayat keluarga, makanan tinggi kalori, merokok, monitor kalori
FCVC, NCP, CH2O, FAF, TUE	Ordinal	Konsumsi sayur, jumlah makan, air putih, aktivitas fisik, waktu layar
CAEC, CALC	Ordinal	Frekuensi ngemil dan konsumsi alkohol
MTRANS	Nominal	Moda transportasi harian
NObeyesdad (Target)	Kategorik 7 kelas	Insufficient Weight s.d. Obesity Type III

3.3 Definisi Tugas & Etika Data

Target NObeyesdad bersifat diskret dengan tujuh kelas sehingga tugas ini tergolong supervised multi-class classification, bukan regresi atau klustering. Dataset tidak memuat identitas pribadi sehingga tidak ada risiko re-identifikasi, namun atribut kesehatan tetap diperlakukan sensitif — input pengguna pada dashboard tidak disimpan permanen. Aplikasi mencantumkan disclaimer agar hasil prediksi tidak digunakan sebagai diagnosis medis final, dan dataset hanya digunakan untuk kepentingan akademik.

BAB IV

AUDIT DATA DAN PREPROCESSING

4.1 Audit Kualitas Data Awal

Aspek	Hasil
Jumlah baris / kolom	2.111 baris; 17 kolom (16 fitur + 1 target)
Missing value	0 (dataset bersih)
Data duplikat	24 baris identik
Baris mengandung outlier (IQR)	702 baris (33,3%) — terbanyak pada NCP (579) dan Age (168)

4.2 Pembersihan, Encoding, dan Scaling

Setelah penghapusan duplikat dan outlier (metode IQR), data tersisa 1.388 baris dari 2.111 (turun 34,3%). Sembilan kolom kategorik dikonversi menggunakan label encoding manual (mapping eksplisit) agar urutan ordinal dapat dikontrol, misalnya CAEC dan CALC (No=0 s.d. Always=3) serta target NObeyesdad (0–6 sesuai urutan keparahan).

Min-Max Scaler dipilih sebagai scaler final karena sebagian besar fitur numerik berskala ordinal sempit (0–3/1–4) dan KNN serta SVM sensitif terhadap skala fitur berbasis jarak/margin. Robust Scaler dipertimbangkan namun dianggap tidak diperlukan karena outlier ekstrem sudah ditangani terpisah.

4.3 Class Imbalance dan Pencegahan Data Leakage

Distribusi tujuh kelas target relatif merata pada data bersih (141–323 sampel per kelas). Balancing (undersampling ke 218 sampel/kelas atau SMOTE ke 281 sampel/kelas) hanya diterapkan pada partisi latih setelah train_test_split, agar tidak terjadi kebocoran informasi. Scaler juga di-fit hanya pada data latih (fit_transform pada X_train, transform pada X_test), dan split menggunakan stratify=y. Tidak ditemukan indikasi data leakage langsung seperti fitur turunan target.

BAB V

DESAIN EKSPERIMEN

5.1 Skema Pembagian Data dan Algoritma

Seluruh eksperimen menggunakan holdout split 80:20 (`random_state=42`, `stratify=y`), dilakukan setelah encoding namun sebelum scaling/resampling. Pada data cleaning (1.388 baris), split menghasilkan 1.110 data latih dan 278 data uji yang tidak pernah disentuh proses balancing maupun fit scaler.

Setiap algoritma diuji dalam dua tahap: baseline (hyperparameter default scikit-learn) dan optimized (hasil GridSearchCV / manual tuning). Algoritma wajib adalah KNN, Naive Bayes, dan SVM; ditambahkan Decision Tree dan Random Forest sebagai pembanding, sehingga total 5 algoritma diuji pada 6 skenario data (Original, Original+Undersampling, Original+SMOTE, Cleaning, Cleaning+Undersampling, Cleaning+SMOTE).

5.2 Metrik Evaluasi

- Accuracy — proporsi prediksi benar, namun rentan bias pada kelas tidak seimbang.
- Precision & Recall (macro-average) — bobot setara untuk ketujuh kelas.
- F1-Score (macro-average) — dijadikan metrik keputusan utama karena menyeimbangkan false positive dan false negative secara merata antar kelas.

BAB VI

HASIL EKSPERIMEN

6.1 Ringkasan Performa Model Terbaik per Algoritma

Tabel berikut merangkum hasil terbaik (setelah optimasi) dari setiap algoritma pada skenario data cleaning, yang menjadi acuan utama pemilihan model final.

Algoritma	Skenario Terbaik	Accuracy	Precision	Recall	F1-Macro
SVM	Cleaning, Optimized	0.9640	0.9571	0.9610	0.9580
Random Forest	Cleaning+SMOTE	0.9568	0.9595	0.9450	0.9495
Decision Tree	Cleaning+SMOTE	0.9568	0.9500	0.9502	0.9499
KNN	Cleaning+SMOTE, Optimized	0.7986	0.7707	0.7768	0.7687
Naive Bayes	Cleaning+SMOTE, Optimized	0.7086	0.7260	0.6558	0.6456

Secara umum, hyperparameter tuning meningkatkan performa seluruh model, dengan peningkatan paling signifikan pada SVM — dari Accuracy 0,827 (baseline) menjadi 0,964 (optimized) pada data cleaning. Data hasil pembersihan (cleaning) juga terbukti memberikan performa lebih baik dibandingkan data asli untuk model SVM, meskipun Decision Tree dan Random Forest justru sedikit lebih baik pada data asli karena tidak terlalu terpengaruh outlier.

6.2 Error Analysis

- Dari 278 data uji, SVM meleset pada 10 sampel (3,6%) — seluruhnya antar kelas bertetangga langsung, tanpa kesalahan yang melompat dua tingkat atau lebih.
- Pola dominan kesalahan: Normal Weight tertukar Overweight Level I/Insufficient Weight, serta Overweight Level I–II saling tertukar, dengan BMI sampel salah berkisar 24,2–24,8 — tepat di sekitar ambang WHO BMI 25.
- Permutation importance menunjukkan Weight paling dominan (penurunan F1-macro 0,728), diikuti Height (0,322), Gender (0,139), dan Age (0,057); fitur gaya hidup nyaris tidak berkontribusi.
- Kesalahan mencerminkan ambiguitas inheren data di sekitar garis batas BMI, bukan kelemahan model.

BAB VII PEMBAHASAN

7.1 Model Terbaik dan Alasan Akademik

Support Vector Machine (SVM) merupakan model dengan performa terbaik dibandingkan KNN, Naive Bayes, Decision Tree, dan Random Forest. Pada skenario data cleaning dengan hyperparameter tuning, SVM memperoleh Accuracy 96,40%, Precision 95,71%, Recall Macro 96,10%, dan F1-Score Macro 95,80%. KNN meningkat setelah tuning namun tetap di bawah SVM; Naive Bayes memiliki performa paling rendah karena asumsi independensi antar fitur kurang sesuai dengan karakteristik dataset; Decision Tree dan Random Forest memiliki akurasi tinggi namun sedikit di bawah SVM.

Performa SVM yang unggul dipengaruhi oleh kemampuannya membentuk hyperplane optimal untuk memisahkan kelas pada dataset dengan hubungan non-linear antar atribut (berat badan, tinggi badan, usia, kebiasaan hidup), terutama setelah preprocessing dan hyperparameter tuning diterapkan. Tahapan pembersihan data, encoding, normalisasi Min-Max, dan penanganan class imbalance turut memberikan kontribusi signifikan terhadap peningkatan performa model.

7.2 Implikasi bagi Institusi

Model yang dikembangkan dapat dimanfaatkan sebagai alat bantu skrining awal bagi institusi pendidikan maupun fasilitas kesehatan, membantu meningkatkan kesadaran masyarakat terhadap pola hidup sehat. Namun, hasil prediksi bukan diagnosis medis dan tidak menggantikan pemeriksaan tenaga kesehatan profesional — aplikasi ini berfungsi sebagai decision support system yang sejalan dengan prinsip Outcome Based Education (OBE).

BAB VIII DESAIN APLIKASI

8.1 Arsitektur dan Alur Kerja

Aplikasi dikembangkan menggunakan Python dengan Streamlit sebagai antarmuka utama dan FastAPI sebagai penyedia layanan API. Model terbaik (SVM) dan scaler disimpan dalam format Joblib pada folder Models/ agar dapat digunakan kembali tanpa training ulang. Alur kerja: pengguna memasukkan data melalui Streamlit → data diproses dengan tahapan preprocessing yang sama seperti saat training (encoding dan Min-Max scaling) → model SVM menghasilkan prediksi → hasil ditampilkan kembali beserta informasi pendukung.

8.2 Struktur Menu

- Dashboard Data — informasi dataset dan distribusi kelas.
- Prediktor Tingkat Obesitas — form input data pengguna dan hasil prediksi beserta probabilitas tiap kelas.
- Perbandingan Eksperimen — visualisasi evaluasi 5 algoritma pada 6 skenario data.
- Interpretasi Model — Permutation Feature Importance dan Learning Curve untuk model SVM terbaik.

8.3 Cara Menjalankan Program

Instal dependensi dari requirements.txt, lalu jalankan streamlit run app_streamlit.py (atau api_fastapi.py untuk layanan API). Project juga menyediakan Dockerfile dan docker-compose.yml sehingga dapat dijalankan dengan docker compose up --build tanpa instalasi manual.

BAB IX

KESIMPULAN DAN REKOMENDASI

9.1 Kesimpulan

Penelitian ini berhasil membangun sistem klasifikasi tingkat obesitas dengan membandingkan lima algoritma (KNN, Naive Bayes, SVM, Decision Tree, Random Forest) pada enam skenario pengolahan data. Algoritma SVM pada skenario data cleaning memberikan performa terbaik dengan Accuracy 96,40%, Precision 95,71%, Recall Macro 96,10%, dan F1-Score Macro 95,80%. Hasil ini menunjukkan bahwa proses pembersihan data dan hyperparameter tuning meningkatkan kualitas model secara signifikan.

Model berhasil diimplementasikan ke dalam aplikasi Streamlit dengan fitur dashboard analisis, prediksi, perbandingan eksperimen, dan interpretasi model. Permutation Feature Importance menunjukkan Weight, Height, Gender, Age, dan FCVC sebagai variabel paling berpengaruh terhadap keputusan model.

9.2 Keterbatasan dan Rekomendasi

- Dataset publik belum tentu merepresentasikan kondisi masyarakat Indonesia secara penuh.
- Aplikasi masih bersifat prototipe tanpa autentikasi pengguna atau penyimpanan riwayat prediksi.
- Rekomendasi: memperluas dataset, menambahkan algoritma modern (XGBoost, LightGBM, CatBoost, Deep Learning), serta melakukan deployment berbasis cloud dengan integrasi database.

BAB X

LAMPIRAN

10.1 Struktur Project (Ringkas)

Data/ (dataset & dokumentasi) · Models/ (model & scaler) · Notebook/ (eksperimen) · Src/ (data_generator.py, ml_core.py, train.py, predict.py) · app_streamlit.py · api_fastapi.py · Dockerfile, docker-compose.yml · requirements.txt · README.md · Reports/ (hasil evaluasi lengkap).

10.2 Tautan

- Repository: <https://github.com/tegarscaesario/obesityprediction>
- Demo aplikasi:
https://drive.google.com/drive/folders/1mQ3qgV8gsEzcwnxQ2hwm05ehSzXwQGpb?usp=drive_link